

信息论

Leo Yan

2026 年 5 月 5 日

目录

第一章 熵, 相对熵, 互信息	4
1.1 基本概念	4
1.2 多维随机变量	5
1.3 不等式	7
1.4 其他背景下的不等式	8
1.5 另一视角下的熵	10
第二章 渐进均分性	12
2.1 渐进均分性	12
第三章 熵率与Markov链	14
3.1 熵率	14
3.2 Markov链	14
第四章 数据压缩	17
4.1 编码理论	17
4.2 Huffman编码	21
4.3 其他编码	23
4.3.1 香农码	23
4.3.2 费纳(Fano)编码	23
4.3.3 Shannon-Fano-Elias编码	23
第五章 信道容量	25
5.1 通信系统模型	25
5.2 联合典型序列	29
5.3 信道编码定理	30
5.4 反馈容量	32
5.5 信源信道分离定理	33
第六章 微分熵	36
6.1 微分熵	36
6.2 连续随机变量的AEP	38
6.3 微分熵与离散熵的关系	39
6.4 微分熵, 相对熵与互信息的性质	40

目录	3
第七章 最后一页	44

第一章 熵，相对熵，互信息

1.1 基本概念

Definition 1.1.1 (熵). 设 X 是离散型随机变量，取值（样本空间）为 $\mathcal{X}$ ，概率分布为 $p(x)$ ，则 X 的熵(entropy)定义为

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log p(x) = \mathbb{E}_p \left[\log \frac{1}{p(X)} \right]$$

单位为比特（bit）；若以自然对数为底，则单位为纳特（nat）

$$H(X) \geq 0; \quad H_b(X) = \log_b a \cdot H_a(X)$$

也记为 $H(p)$

Remark 1.1.1. 熵描述随机变量的不确定度；给出了描述随机变量所需的信息量的下界

Definition 1.1.2 (联合熵). 设 (X,Y) 为联合分布的离散型随机变量，则 (X,Y) 的联合熵(joint entropy)定义为

$$H(X,Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log p(x,y) = \mathbb{E}_p \left[\log \frac{1}{p(X,Y)} \right]$$

也记为 $H(XY)$

Definition 1.1.3 (条件熵). 设 (X,Y) 为联合分布的离散型随机变量，则在已知 Y 的条件下 X 的条件熵(conditional entropy)定义为

$$H(X|Y) = - \sum_{y \in \mathcal{Y}} p(y) \sum_{x \in \mathcal{X}} p(x|y) \log p(x|y) = \mathbb{E}_p \left[\log \frac{1}{p(X|Y)} \right]$$

Theorem 1.1.1 (链式法则). 设 (X,Y) 为联合分布的离散型随机变量，则有

$$H(X,Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

Proof.

$$H(X,Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log p(x,y)$$

$$\begin{aligned}
&= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x)p(y|x) \log[p(x)p(y|x)] \\
&= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(x) - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(y|x) \\
&= H(X) + H(Y|X)
\end{aligned}$$

□

Definition 1.1.4 (相对熵). 设 p 和 q 为定义在同一样本空间 $\mathcal{X}$ 上的两个离散概率分布, 则 p 相对于 q 的**相对熵**(relative entropy)或Kullback-Leibler散度(KL散度)定义为

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} = \mathbb{E}_p \left[\log \frac{p(X)}{q(X)} \right]$$

Remark 1.1.2. 描述两个概率分布之间的差异; 真实分布为 p , 假设分布为 q 的无效性

Definition 1.1.5 (互信息). 设 (X, Y) 为联合分布的离散型随机变量, 则 X 和 Y 的**互信息**(mutual information)定义为

$$I(X; Y) = D(p(x, y)||p(x)p(y)) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log \frac{p(x, y)}{p(x)p(y)} = \mathbb{E}_p \left[\log \frac{p(X, Y)}{p(X)p(Y)} \right]$$

Remark 1.1.3. 描述两个随机变量之间共享的信息量, 或 X 包含 Y 的信息量

Proposition 1.1.2 (互信息的性质). 设 (X, Y) 为联合分布的离散型随机变量, 则有

1. $I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$
2. $I(X; Y) = H(X) + H(Y) - H(X, Y)$
3. $I(X; X) = H(X)$

Remark 1.1.4. 以上三条性质的直观:

- 给定 X , Y 的不确定性减少了 $I(X; Y)$
- 容斥原理
- 熵又是自信息(self-information)

1.2 多维随机变量

符号说明

- (1) $H(X, Y, Z)$ 实际上应该理解为 $H((X, Y, Z))$, 即 H 总为一元函数
- (2) $I(X; Y, Z)$ 实际上应该理解为 $I(X; (Y, Z))$, 即 $I(\cdot; \cdot)$ 总为二元函数
- (3) $H(X, Y|Z)$ 实际上应该理解为 $H((X, Y)|Z)$, 即 $H(\cdot|\cdot)$ 总为二元函数; 同理 $I(X; Y|Z)$ 实际上应该理解为 $I(X; Y|Z)$, 即 $I(\cdot; \cdot|\cdot)$ 总为三元函数。应该认为“;”的优先级高于“|”
- (4) D 虽称为熵, 但不是随机变量的函数, 而是分布的函数。”||”类似于“;”, D 总为二元函数

Definition 1.2.1 (条件互信息). X, Y 在已知 Z 的条件下的条件互信息(conditional mutual information)定义为

$$I(X; Y|Z) = \sum_{z \in \mathcal{Z}} p(z) \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y|z) \log \frac{p(x, y|z)}{p(x|z)p(y|z)} = \mathbb{E}_p \left[\log \frac{p(X, Y|Z)}{p(X|Z)p(Y|Z)} \right]$$

Remark 1.2.1. 描述已知 Z , 给出 Y 引起的 X 的不确定度减少量

Definition 1.2.2 (条件相对熵). 对于联合概率质量函数 $p(x, y)$ 和 $q(x, y)$, X 在已知 Y 的条件下的条件相对熵(conditional relative entropy)定义为

$$D(p(x|y)||q(x|y)) = \sum_{y \in \mathcal{Y}} p(y) \sum_{x \in \mathcal{X}} p(x|y) \log \frac{p(x|y)}{q(x|y)} = \mathbb{E}_p \left[\log \frac{p(X|Y)}{q(X|Y)} \right]$$

Theorem 1.2.1 (熵的链式法则).

$$H(X_1, X_2, \dots, X_n) = \sum_{i=1}^n H(X_i|X_1, X_2, \dots, X_{i-1})$$

Proof. 反复使用

$$H(X, Y) = H(X) + H(Y|X)$$

□

Theorem 1.2.2 (互信息的链式法则).

$$I(X; Y_1, Y_2, \dots, Y_n) = \sum_{i=1}^n I(X; Y_i|Y_1, Y_2, \dots, Y_{i-1})$$

Proof.

$$I(\mathbf{X}; \mathbf{Y}) = H(\mathbf{Y}) - H(\mathbf{Y}|\mathbf{X})$$

□

Theorem 1.2.3 (相对熵的链式法则).

$$D(p(x, y)||q(x, y)) = D(p(x)||q(x)) + D(p(y|x)||q(y|x))$$

Proof.

$$\begin{aligned} D(p(x, y)||q(x, y)) &= \mathbb{E}_{p(x, y)} \log \frac{p(X, Y)}{q(X, Y)} \\ &= \mathbb{E}_{p(x, y)} \log \frac{p(X)p(Y|X)}{q(X)q(Y|X)} \\ &= \mathbb{E}_{p(x)} \log \frac{p(X)}{q(X)} + \mathbb{E}_{p(x, y)} \log \frac{p(Y|X)}{q(Y|X)} \\ &= D(p(x)||q(x)) + D(p(y|x)||q(y|x)) \end{aligned}$$

□

1.3 不等式

Theorem 1.3.1 (Jensen不等式). 设 X 为离散型随机变量, 取值(样本空间)为 $\mathcal{X}$, 概率分布为 $p(x)$, 且 f 为凸函数, 则有

$$\mathbb{E}_p[f(X)] \geq f(\mathbb{E}_p[X])$$

进一步, 若 f 为严格凸函数, 则等号成立 $\iff X = \mathbb{E}X$

Theorem 1.3.2 (信息不等式). 设 p 和 q 为定义在同一样本空间 $\mathcal{X}$ 上的两个离散概率分布, 则有

$$D(p||q) \geq 0$$

取等 $\iff p = q$

Proof. $\log$ 在 $(0, +\infty)$ 上为严格凹函数, 故 $-\log$ 为严格凸。考虑

$$A = \{x \in \mathcal{X} : p(x) > 0, q(x) > 0\}$$

则由Jensen不等式,

$$\begin{aligned} D(p||q) &= \sum_{x \in A} p(x) \log \frac{p(x)}{q(x)} \\ &= - \sum_{x \in A} p(x) \left[-\log \frac{q(x)}{p(x)} \right] \\ &\geq -\log \left(\sum_{x \in A} p(x) \frac{q(x)}{p(x)} \right) \\ &= -\log \left(\sum_{x \in A} q(x) \right) \\ &\geq 0 \end{aligned}$$

□

Corollary 1.3.3.

$$I(X; Y) \geq 0$$

取等 $\iff X$ 与 Y 独立

条件相对熵、条件互信息也是非负的

Corollary 1.3.4.

$$H(X|Y) \leq H(X)$$

取等 $\iff X$ 与 Y 独立

Remark 1.3.1. 条件导致熵减小。但 $H(X|Y = y)$ 可能大于 $H(X)$, 不等式仅描述平均性质

Theorem 1.3.5.

$$H(X) \leq \log |\mathcal{X}|$$

取等 $\iff X \sim U_{\mathcal{X}}$

Corollary 1.3.6 (熵的独立界).

$$H(X_1, X_2, \dots, X_n) \leq \sum_{i=1}^n H(X_i)$$

取等 $\iff X_1, X_2, \dots, X_n$ 相互独立

Proof. 由链式法则,

$$H(X_1, X_2, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, X_2, \dots, X_{i-1}) \leq \sum_{i=1}^n H(X_i)$$

□

1.4 其他背景下的不等式

Definition 1.4.1. 如果Z的条件分布 $p(z|x, y)$ 仅依赖于y而与x条件独立, 即

$$p(x, y, z) = p(x)p(y|x)p(z|y)$$

则称随机变量三元组 (X, Y, Z) 构成马尔可夫链(Markov chain), 记为 $X \rightarrow Y \rightarrow Z$
条件独立的意思是

$$p(x, z|y) = p(x|y)p(z|y)$$

X, Z 对称, 即 $X \rightarrow Y \rightarrow Z \iff Z \rightarrow Y \rightarrow X$, 因此可记 $X \leftrightarrow Y \leftrightarrow Z$

Theorem 1.4.1 (数据处理不等式). 设随机变量三元组 (X, Y, Z) 构成马尔可夫链 $X \rightarrow Y \rightarrow Z$, 则有

$$I(X; Y) \geq I(X; Z)$$

取等 $\iff X \rightarrow Z \rightarrow Y$

Proof. 用互信息的链式法则,

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) = I(X; Z) + I(X; Y|Z)$$

给定Y, X与Z独立, 即 $I(X; Z|Y) = 0$, 而 $I(X; Y|Z) \geq 0$, 故

$$I(X; Y) \geq I(X; Z)$$

□

Remark 1.4.1. 对Y的数据处理不能增加其包含X的信息

Corollary 1.4.2.

$$I(X;Y) \geq I(X, g(Y))$$

$$X \rightarrow Y \rightarrow Z \implies I(X;Y|Z) \leq I(X;Y)$$

Remark 1.4.2. 观察下游随机变量, X, Y 的依赖程度可能降低

Definition 1.4.2 (充分统计量). 假定有一族概率质量函数 $\{f_\theta(x)\}$, X 是从其中一个分布 $f_\theta(x)$ 中抽取的样本, $T(X)$ 是 X 的一个统计量, 则

$$\theta \rightarrow X \rightarrow T(X)$$

由数据处理不等式, 有

$$I(\theta; X) \geq I(\theta; T(X))$$

取等时统计量 $T(X)$ 未损失 X 关于参数 θ 的信息, 称 $T(X)$ 为关于分布族 $\{f_\theta(x)\}$ 的充分统计量 (sufficient statistic)

等价定义: 给定 $T(X)$, X 与 θ 条件独立, 即 $\theta \rightarrow T(X) \rightarrow X$

Definition 1.4.3 (最小充分统计量). 关于分布族 $\{f_\theta(x)\}$ 的充分统计量 $T(X)$ 是其他任何充分统计量 $U(X)$ 的函数, 则称 $T(X)$ 为关于 $\{f_\theta(x)\}$ 的最小充分统计量 (minimal sufficient statistic)

定义蕴含 $\theta \rightarrow T(X) \rightarrow U(X) \rightarrow X$

Remark 1.4.3. 最小充分统计量最大程度地压缩了样本 X 中关于 θ 的信息, 而其他充分统计量可能包含冗余信息

由随机变量 Y 估计与之有关的 X , X 的估计值记为 $\hat{X} = g(Y)$ 取值空间为 $\hat{\mathcal{X}}$, 则有马尔可夫链

$$X \rightarrow Y \rightarrow \hat{X}$$

定义误差概率 $P_e = P\{\hat{X} \neq X\}$ 。

Theorem 1.4.3 (Fano不等式). 设 X 为离散型随机变量, 取值 (样本空间) 为 $\mathcal{X}$, 则有

$$H(P_e) + P_e \log(|\mathcal{X}| - 1) \geq H(X|\hat{X}) \geq H(X|Y)$$

可减弱为

$$1 + P_e \log |\mathcal{X}| \geq H(X|Y) \implies P_e \geq \frac{H(X|Y) - 1}{\log |\mathcal{X}|}$$

Proof. 设错误指示变量 $E = \mathbb{1}_{\{\hat{X} \neq X\}}$, 则有马尔可夫链 $X \rightarrow Y \rightarrow \hat{X} \rightarrow E$ 。由链式法则,

$$\begin{aligned} H(X, E|\hat{X}) &= H(E|\hat{X}) + H(X|E, \hat{X}) \\ &= H(X|\hat{X}) + H(E|X, \hat{X}) \end{aligned}$$

因为 $H(E|X, \hat{X}) = 0$, 所以

$$H(X|\hat{X}) = H(E|\hat{X}) + H(X|E, \hat{X})$$

注意到

$$H(E|\hat{X}) \leq H(E) = H(P_e)$$

且

$$H(X|E, \hat{X}) = P_e H(X|\hat{X}, E=1) + (1-P_e) H(X|\hat{X}, E=0) \leq P_e \log(|\mathcal{X}| - 1)$$

故

$$H(X|\hat{X}) \leq H(P_e) + P_e \log(|\mathcal{X}| - 1)$$

另一方面, 由数据处理不等式,

$$H(X|Y) \leq H(X|\hat{X})$$

□

Corollary 1.4.4. 令 $\hat{X} = Y$, 则有

$$H(P_e) + P_e \log(|\mathcal{X}| - 1) \geq H(X|Y)$$

若 $\hat{X} = X$, 结论变为

$$H(P_e) + P_e \log(|\mathcal{X}| - 1) \geq 0$$

Proposition 1.4.5. 设 X, X' 独立同分布, 则

$$P\{X = X'\} \geq 2^{-H(X)}$$

Corollary 1.4.6. 设 X, Y 独立, $X \sim p(x)$, $Y \sim q(y)$, 取值空间均为 $\mathcal{X}$, 则

$$P\{X = Y\} \geq 2^{-H(p) - D(p||q)}, P\{X = Y\} \geq 2^{-H(q) - D(q||p)}$$

1.5 另一视角下的熵

参考《通信原理》第五版 (杨鸿文)

Definition 1.5.1. 对于单消息离散信源, 随 x_i 出现概率由 0 增大至 1, 发送 $X = x_i$ 提供的信息由 ∞ 递减至 0, 由此定义单个离散消息 $X = x_i$ 的自信息量为

$$I[P(x_i)] = \log \frac{1}{P(x_i)}$$

这样, 单消息离散信源的信息熵为自信息量的期望:

$$H(X) = \mathbb{E}[I(P(x_i))] = - \sum P(x_i) \log P(x_i)$$

自信息量可以对条件概率、联合概率定义, 因此条件熵、联合熵也可看作是自信息量的期望, 例如

$$H(X|Y) = \mathbb{E}[I[P(x_i|y_j)]]$$

Definition 1.5.2. 设 X 为信源， Y 为信宿，收发一对具体的 x_i, y_j 值时的互信息成为信源与信宿之间的互信息密度：

$$i(x_i, y_j) = \log \frac{P(x_i|y_j)}{P(x_i)} = \log \frac{P(y_j|x_i)}{P(y_j)}$$

互信息可以看作是互信息密度的期望：

$$I(X; Y) = \mathbb{E}[i(x_i|y_j)]$$

它可以理解为信宿 Y 获得信源 X 的信息量，或者说信源发送给信宿的信息量。

第二章 渐进均分性

2.1 渐进均分性

Definition 2.1.1 (随机变量的收敛). 给定随机变量序列 $\{X_n\}$ 和随机变量 X ,

①如果

$$\forall \epsilon > 0, P\{|X_n - X| \geq \epsilon\} \rightarrow 0 (n \rightarrow \infty)$$

则称 X_n 依概率收敛于 X , 记为 $X_n \xrightarrow{P} X$

②如果

$$P\{\lim_{n \rightarrow \infty} X_n = X\} = 1$$

则称 X_n 几乎处处收敛(或以概率1收敛)于 X , 记为 $X_n \xrightarrow{a.e.} X$

③如果

$$\mathbb{E}(X_n - X)^2 \rightarrow 0 (n \rightarrow \infty)$$

则称 X_n 均方收敛于 X , 记为 $X_n \xrightarrow{L_2} X$

Theorem 2.1.1 (渐进均分性(Asymptotic Equipartition Property, AEP)). 以 X 记信源随机变量, 它生成的序列 $X_1, X_2, \dots, X_n$ i.i.d. $\sim p(x)$, 则有

$$-\frac{1}{n} \log p(X_1, X_2, \dots, X_n) \xrightarrow{P} H(X)$$

Proof.

$$X_k \text{ i.i.d. } \sim p(x) \implies -\log p(X_k) \text{ i.i.d. } \sim -\log p(x)$$

由弱大数定律,

$$\frac{1}{n} \sum_{k=1}^n -\log p(X_k) \xrightarrow{P} \mathbb{E}[-\log p(X)] = H(X)$$

□

Definition 2.1.2 (典型集). 关于 $p(x)$ 的典型集(typical set)定义为

$$A_\epsilon^{(n)} = \left\{ (x_1, x_2, \dots, x_n) : \left| -\frac{1}{n} \log p(x_1, x_2, \dots, x_n) - H(X) \right| < \epsilon \right\}$$

性质:

①

$$\forall \mathbf{x} \in A_\epsilon^{(n)}, H(X) - \epsilon < -\frac{1}{n} \log p(\mathbf{x}) < H(X) + \epsilon$$

- ② n 充分大时, $P\{A_\epsilon^{(n)}\} > 1 - \epsilon$
- ③ $|A_\epsilon^{(n)}| \leq 2^{n(H(X)+\epsilon)}$ (概率和不超过1)
- ④ (第一条的推论) n 充分大时, $|A_\epsilon^{(n)}| \geq (1 - \epsilon)2^{n(H(X)-\epsilon)}$

Remark 2.1.1. 直观:

- ① $\implies$ 典型集中的元素在数量级意义下是几乎等可能的;
- ② $\implies$ 典型集出现概率随 n 增大而趋近于1 (渐进);
- ③④ $\implies$ 典型集的元素个数近似等于 $2^{nH(X)}$ (均分)

设 X_n *i.i.d.* $\sim p(x)$, 存在一个编码将长为 n 的序列映射为比特串, 且映射为双射 (从而可逆), 其码字长度 $l(x_n)$ 满足

$$\lim_{n \rightarrow \infty} \mathbb{E} \left[\frac{1}{n} l(x_n) \right] = H(X)$$

因而理论上用 $nH(X)$ 比特即可表示序列 $x_1, x_2, \dots, x_n$ (等长码需要 $n \log |\mathcal{X}|$ 比特)

码字长度: 信源编码时某个符号 x 使用的比特数为 $l(x)$; x^n 使用的比特数为 $l(x^n)$

Proof. 考虑给大概率的典型集较短的编码。

$$A_\epsilon^{(n)} \leq 2^{n(H(X)+\epsilon)} \implies [n(H(X) + \epsilon)] \leq n(H(X) + \epsilon) + 1(\text{bit})$$

可表示 $A_\epsilon^{(n)}$ 中的每个序列, 同理 $n \log |\mathcal{X}| + 1$ bit可表示 $A_\epsilon^{(n)c}$

在典型集序列前标0而在非典型集序列前标1作为表示为, 则码字长度

$$l(x^n) \leq \begin{cases} n(H(X) + \epsilon) + 2, & x^n \in A_\epsilon^{(n)} \\ n \log |\mathcal{X}| + 2, & x^n \in A_\epsilon^{(n)c} \end{cases}$$

取 n 充分大使 $P\{A_\epsilon^{(n)}\} > 1 - \epsilon$, 则

$$\begin{aligned} \mathbb{E}[l(x^n)] &= \sum_{x^n \in \mathcal{X}^n} p(x^n) l(x^n) \\ &\leq P\{A_\epsilon^{(n)}\} [n(H(X) + \epsilon) + 2] + P\{A_\epsilon^{(n)c}\} [n \log |\mathcal{X}| + 2] \\ &\leq (1 - \epsilon) [n(H(X) + \epsilon) + 2] + \epsilon [n \log |\mathcal{X}| + 2] = n(H(X) + \epsilon') \end{aligned}$$

其中 $\epsilon' = \epsilon \log |\mathcal{X}| - \epsilon H(X) + 2/n$

$$\begin{aligned} \mathbb{E}[l(x^n)] &\geq P\{A_\epsilon^{(n)}\} [n(H(X) + \epsilon) + 1] + P\{A_\epsilon^{(n)c}\} [n \log |\mathcal{X}| + 1] \\ &\geq (1 - \epsilon) [n(H(X) + \epsilon) + 1] + \epsilon [n \log |\mathcal{X}| + 1] = n[(1 - \epsilon)H(X) + \epsilon''] \end{aligned}$$

其中 $\epsilon'' = \epsilon(1 - \epsilon) + \frac{1 - \epsilon}{n}$

□

Remark 2.1.2. 熵是无损压缩的下限

第三章 熵率与Markov链

3.1 熵率

Definition 3.1.1 (熵率). 设 $\{X_n\}$ 为随机过程, 则 $\{X_n\}$ 的熵率(entropy rate)在极限存在时定义为

$$H(\mathcal{X}) = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, X_2, \dots, X_n)$$

Theorem 3.1.1. 定义

$$H'(\mathcal{X}) = \lim_{n \rightarrow \infty} H(X_n | X_1, X_2, \dots, X_{n-1})$$

对于平稳过程, 两种极限均存在且 $H(\mathcal{X}) = H'(\mathcal{X})$

Proof.

$$H(X_{n+1} | X_1, X_2, \dots, X_n) \leq H(X_{n+1} | X_2, X_3, \dots, X_{n+1}) = H(X_n | X_1, X_2, \dots, X_{n-1})$$

因此 $H(X_n | X_1, X_2, \dots, X_{n-1})$ 非负递减, $H'(\mathcal{X})$ 存在。

由链式法则,

$$\frac{1}{n} H(X_1, X_2, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n H(X_i | X_1, X_2, \dots, X_{i-1})$$

即熵率为条件熵的时间平均值。 $H_n(\mathcal{X})$ 为 $H'(\mathcal{X})$ 的Cesàro和, 故 $H(\mathcal{X}) = H'(\mathcal{X})$ □

3.2 Markov链

Theorem 3.2.1. 对于平稳的Markov链 $\{X_n\}$, 设平稳分布为 μ , 转移概率矩阵为 P , 则熵率为

$$H(\mathcal{X}) = H(X_2 | X_1) = \sum_i \mu_i \sum_j P_{ij} \log \frac{1}{P_{ij}}$$

Proof.

$$\begin{aligned} H'(\mathcal{X}) &= \lim_{n \rightarrow \infty} H(X_n | X_1, X_2, \dots, X_{n-1}) \\ &= \lim_{n \rightarrow \infty} H(X_n | X_{n-1}) \\ &= H(X_2 | X_1) \end{aligned}$$

$$= \sum_i \mu_i \sum_j P_{ij} \log \frac{1}{P_{ij}}$$

□

Theorem 3.2.2. 设 μ_n, μ'_n 为 n 时刻同一Markov链的两条轨迹的分布, 则

$$D(\mu_n || \mu'_n) \geq D(\mu_{n+1} || \mu'_{n+1})$$

特别地,

$$D(\mu_n || \mu) \geq D(\mu_{n+1} || \mu)$$

Proof. 记 μ_n, μ'_n 对应两盒概率分布为 p, q , $r(\cdot|\cdot)$ 为转移概率分布, 则

$$p(x_n, x_{n+1}) = p(x_n)r(x_{n+1}|x_n), q(x_n, x_{n+1}) = q(x_n)r(x_{n+1}|x_n)$$

由相对熵的链式法则,

$$\begin{aligned} D(p(x_n)||q(x_n)) \\ &= D(p(x_n)||q(x_n)) + D(r(x_{n+1}|x_n)||r(x_{n+1}|x_n)) \\ &= D(p(x_{n+1})||q(x_{n+1})) + D(p(x_n|x_{n+1})||q(x_n|x_{n+1})) \end{aligned}$$

由于 $D(r||r) = 0, D(p||q) \geq 0$, 因此 $D(p(x_n)||q(x_n)) \geq D(p(x_{n+1})||q(x_{n+1}))$, 即 $D(\mu_n || \mu'_n) \geq D(\mu_{n+1} || \mu'_{n+1})$ 。 □

Remark 3.2.1. 相同转移概率下, 不同初始分布趋同于平稳分布

Corollary 3.2.3. 若平稳分布 μ 为均匀分布, 则熵增大, 即 $H(\mu_n) \leq H(\mu_{n+1})$

Proof.

$$\begin{aligned} D(\mu_n || \mu) &= \sum_{x_n} \mu_n(x_n) \log \frac{\mu_n(x_n)}{1/|\mathcal{X}|} \\ &= \log |\mathcal{X}| - H(\mu_n) \\ &= \log |\mathcal{X}| - H(X_n) \end{aligned}$$

□

Remark 3.2.2. 热学中的熵 $S = \log \Omega$ 在各状态等可能的前提下与信息熵一致, 这解释了热二律“熵增大”

Definition 3.2.1. 转移概率矩阵 P 的行和为1: $\sum_j P_{ij} = 1$, 且 $P_{ij} \geq 0$ 。若 P 列和也为1: $\sum_i P_{ij} = 1$, 则 P 是双随机矩阵(doubly stochastic matrix)
均匀分布是平稳分布 $\iff P$ 双随机

Theorem 3.2.4. 对于平稳的Markov链 $\{X_n\}$, $H(X_{n+1}|X_1) \geq H(X_n|X_1)$

Proof.

$$H(X_{n+1}|X_1) \geq H(X_{n+1})|X_1, X_2 = H(X_{n+1})|X_2 = H(X_n|X_1)$$

□

Lemma 3.2.5. 设 $\{X_n\}$ 为平稳的Markov链, $\{Y_n\}$ 为 $\{X_n\}$ 的对应项的函数, 熵率为 $H(\mathcal{Y})$, 则

$$H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \leq H(\mathcal{Y})$$

Proof.

$$\begin{aligned} H(Y_n|Y_{n-1}, \dots, Y_1, X_1) &\leq H(Y_n|Y_{n-1}, \dots, Y_1, X_1, X_0, \dots, X_{-k}) && \text{(Markov性)} \\ &= H(Y_n|Y_{n-1}, \dots, Y_1, \dots, Y_{-k}, X_1, X_0, \dots, X_{-k}) && (Y_k = \phi_k(X_k)) \\ &\leq H(Y_n|Y_{n-1}, \dots, Y_1, \dots, Y_{-k}) \\ &= H(Y_{n+k+1}|Y_{n+k}, \dots, Y_1) && \text{(平稳性)} \end{aligned}$$

令 $k \rightarrow \infty$, 则

$$H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \leq \lim_{k \rightarrow \infty} H(Y_{n+k+1}|Y_{n+k}, \dots, Y_1) = H(\mathcal{Y})$$

□

Lemma 3.2.6.

$$H(Y_n|Y_{n-1}, \dots, Y_1) - H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \rightarrow 0, n \rightarrow \infty$$

Proof.

$$\begin{aligned} H(X_1) &\geq \lim_{n \rightarrow \infty} I(X_1; Y_n|Y_{n-1}, \dots, Y_1) \\ &= \sum_{n=1}^{\infty} I(X_1; Y_n|Y_{n-1}, \dots, Y_1) && \text{(链式法则)} \\ &= \sum_{n=1}^{\infty} [H(Y_n|Y_{n-1}, \dots, Y_1) - H(Y_n|Y_{n-1}, \dots, Y_1, X_1)] \end{aligned}$$

□

又由3.1.1,

$$\{X_n\} \text{平稳} \implies H(X_n|X_1, X_2, \dots, X_{n-1}) \downarrow H(\mathcal{X})$$

Theorem 3.2.7. 设 $\{X_n\}$ 为平稳的Markov链, $\{Y_n\}$ 为 $\{X_n\}$ 的对应项的函数, 熵率为 $H(\mathcal{Y})$, 则

$$H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \leq H(\mathcal{Y}) \leq H(Y_n|Y_{n-1}, \dots, Y_1)$$

且

$$\lim_{n \rightarrow \infty} H(Y_n|Y_{n-1}, \dots, Y_1, X_1) = H(\mathcal{Y}) = \lim_{n \rightarrow \infty} H(Y_n|Y_{n-1}, \dots, Y_1)$$

第四章 数据压缩

4.1 编码理论

Definition 4.1.1 (字母表). 设 X 是取值空间为 $\mathcal{X}$ 的随机变量, Σ 为 D 元字母表(alphabet), Σ^* 表示 Σ 上有限长字符串构成的集合。
总假设 D 元字母表为 $\{0, 1, \dots, D-1\}$ 。

Definition 4.1.2 (信源编码). 信源编码(source code)为映射 $C: \mathcal{X} \rightarrow \Sigma^*$ 。
 x 的码字(codeword)记为 $C(x)$, 其长度记为 $l(x)$
若 C 是单射, 称该编码是非奇异的(nonsingular)。

Definition 4.1.3 (期望长度). 设 $X \sim p(x)$, 信源编码 C 的期望长度(expected length)为

$$L(C) = \mathbb{E}_p l(X) = \sum_{x \in \mathcal{X}} p(x) l(x)$$

Definition 4.1.4 (前缀码). C 是前缀码(prefix code)或即时码(instantaneous code), 如果在序列中任一字符 x_i 的码字结束时, 可以不依赖于后续码字而立即确定 x_i 。
等价定义: 没有任何码字是其他码字的前缀, 即

$$\forall c_1, c_2 \in C, c_1 \neq c_2, !\exists s \in \Sigma^*, c_1 \cdot s = c_2$$

其中 $\cdot$ 为自由群乘法。

Theorem 4.1.1 (Kraft不等式). D 元字母表上的即时码, 码字长度 $l_1, \dots, l_m$ 满足

$$\sum_{i=1}^m D^{-l_i} \leq 1$$

给定一组满足上述不等式的码字长度, 必存在相应的即时码。

Proof. 考虑 D 叉树, 第 k 层为长为 k 的字符串, 树枝表述字符。

前缀条件表明, 没有码字是其他码字的祖先, 即码字必然对应叶子。

令 $l_{\max} = \max\{l_i\}$, 考虑 $l_{\max}$ 层中码字节点及其后代数 M :

一方面, $M \leq D^{l_{\max}}$;

另一方面, 位于 l_i 层的码字在 $l_{\max}$ 层恰有 $D^{l_{\max}-l_i}$ 个后代, 且这些后代胡补充和, 因此

$$M = \sum_i D^{l_{\max}-l_i}$$

综上, $\sum_{i=1}^m D^{-l_i} \leq 1$.

反之, 依字典序将第一个深度为 l_1 的节点标为码字1并去除其后代。依次对 l_i 重复以上步骤。不等式保证直至最后一步, 必然存在所需层的节点。□

Theorem 4.1.2 (推广的Kraft不等式). 任意可数的即时码字集, 码字长度 $\{l_i\}_{i=1}^{\infty}$ 满足

$$\sum_{i=1}^{\infty} D^{-l_i} \leq 1$$

反之也有相应即时码。

Proof. 以D进制小数

$$0.y_1y_2\cdots y_{l_i} = \sum_{j=1}^{l_i} y_j D^{-j}$$

表示码字, 则在区间

$$[0.y_1\cdots y_{l_i}, 0.y_1\cdots y_{l_i} + D^{-l_i})$$

没有其他码字。区间长度之和 ≤ 1 即Kraft不等式。反之构造同上。□

Definition 4.1.5 (D进制概率分布). 如果概率质量函数 p 的每个概率值形如 D^{-n} , $n \in \mathbb{N}$, 则称 p 是D进制的(D-adic)

使用D元字母表, 信源编码的期望长度不小于以D为底的信源分布的熵:

Theorem 4.1.3 (期望长度的估计). 设信源分布为 $p(x_i) = p_i$, 对随机变量 X 的任一D元即时码 C , 令 $d = \sum D^{-l_i} \leq 1$, D进制分布 $q_i = D^{-l_i}/d$, 则

(1)

$$L(C) = H_D(X) + D(p||q) - \log_D c \geq H_D(X)$$

取等时必须满足: 分配最优码长 $l_i^* = -\log_D p_i \in \mathbb{N}^*$.

(2) $-\log_D p_i \in \mathbb{N}^*$ 的必要条件是 p 是D进制分布, 此时 $p=q$.

Proof.

$$\begin{aligned} L(C) - H_D(X) &= \sum p_i l_i - \sum p_i \log_D \frac{1}{p_i} \\ &= \sum p_i \log_D p_i D^{-l_i} \\ &= \sum p_i \log_D \frac{p_i}{q_i} \cdot \frac{1}{c} \\ &= \sum p_i \log_D \frac{p_i}{q_i} - \log_D c \\ &= D(p||q) - \log_D c \geq 0 \end{aligned} \quad (\text{相对熵非负})$$

下面说明 q_i 及最优码长的由来, 即最优化问题:

在 $l_i \in \mathbb{N}, \sum D^{-l_i} \leq 1$ 的条件下, 求 $\min L(C)$.

不考虑 $l_i \in \mathbb{N}, \Omega = \{\mathbf{x} \in \mathbb{R}^m : \sum D^{-l_i} \leq 1\}$ 是凸集, 因为 $\forall \mathbf{x}, \mathbf{y} \in \Omega$, 由Hölder不等式,

$$\sum_i D^{-\lambda x_i - (1-\lambda)y_i} \leq \left(\sum_i D^{-x_i} \right)^\lambda \left(\sum_i D^{-y_i} \right)^{1-\lambda} \leq 1, \forall 0 < \lambda < 1$$

用拉乘法求 $\min_{\mathbf{x} \in \Omega} L(C)$. 令

$$J(l_1, \dots, l_m, \lambda) = \sum_i p_i l_i + \lambda \left(\sum_i D^{-l_i} - 1 \right)$$

再令

$$\frac{\partial J}{\partial l_i} = p_i - \lambda D^{-l_i} \log D = 0$$

得

$$D^{-l_i} = \frac{p_i}{\lambda \log D}$$

代回条件 $\mathbf{x} \in \partial\Omega$ 得 $\lambda = 1/\log D$, 从而最优码长为

$$l_i^* = -\log_D p_i$$

□

以上过程提供了寻找最优编码（在 $D(p||q)$ 最小的意义下）的流程：寻找最接近 $X \sim p$ 的D进制分布q, 按q选取码字长度, 再用Kraft不等式证明中的方法构造编码。按此流程构造的编码是香农码：

Definition 4.1.6 (香农码). 满足 $l_i = -\log_D p_i$ 的编码称为香农码。

以下定理从期望长度的角度阐释了香农码的有效性：

Theorem 4.1.4. 设 $\{l_i^*\}_{i=1}^m$ 是关于信源分布 p 和 D 元字母表的最优码长, $L^* = \sum p_i l_i^*$ 为期望长度, 则

$$H_D(X) \leq L^* < H_D(X) + 1$$

Proof. 令

$$l_i = \left\lceil \log_D \frac{1}{p_i} \right\rceil \in \left[\log_D \frac{1}{p_i}, \log_D \frac{1}{p_i} + 1 \right)$$

它满足Kraft不等式：

$$\sum D^{l_i} \leq \sum D^{-\log \frac{1}{p_i}} = 1$$

这样就构造出在所需区间中的期望长度。

□

下面总令 $D=2$ 。

通过对字符进行分组编码, 可以减少每字符的附加位, 从而降低L:

Theorem 4.1.5. 考虑将 $\mathbf{x} = (x_1, \dots, x_n)$ 视为 $\mathcal{X}^n$ 中的超字符, $l(\mathbf{x})$ 为 $\mathbf{x}$ 的码字长度, 则每输入字符的最小期望码字长度满足

$$\frac{1}{n} H(\mathbf{X}) \leq L_n^* < \frac{1}{n} H(\mathbf{X}) + \frac{1}{n}$$

进一步, 若 $\{X_j\}$ 是平稳过程, 则

$$\lim_{n \rightarrow \infty} L_n^* = H(\mathcal{X})$$

Proof.

$$L_n = \frac{1}{n} \sum p(\mathbf{x}) l(\mathbf{x}) = \frac{1}{n} \mathbb{E} l(\mathbf{X})$$

按

$$l(\mathbf{x}_i) = \left\lceil \log \frac{1}{p(\mathbf{x}_i)} \right\rceil$$

分配码长, 则构造出所需区间中的 L_n 。后一命题得自夹逼定理。 $\square$

以下定理估计了考虑**偏码**(wrong code)时的期望码长:

Theorem 4.1.6. 如果非真实分布 q 是对真实分布 p 的最佳估计, 则在码长分配

$$l(x) = \left\lceil \log \frac{1}{q(x)} \right\rceil$$

下, 关于 $p(x)$ 的期望长度满足:

$$H(p) + D(p||q) \leq \mathbb{E}_p l(X) < H(p) + D(p||q) + 1$$

Proof.

$$l(x) \in \left[\log \frac{1}{q(x)}, \log \frac{1}{q(x)} + 1 \right)$$

类似thm4.1.4. 带入即证。 $\square$

以下定理表明, 仅仅要求编码唯一可译, 而不要求即时性, 也无法找到更小码长:

Theorem 4.1.7 (McMillan定理). 任一唯一可译的 D 元码也满足Kraft不等式 $\sum D^{l_i} \leq 1$; 反之, 给定一组码字长度 $\{l_i\}$ 满足 $\sum D^{l_i} \leq 1$, 必有对应的唯一可译码。

Proof. $\forall k \in \mathbb{N}^*$, 考虑 C 的 k 次扩展, 有

$$l(x_1, \dots, x_k) = \sum_{i=1}^k l(x_i)$$

注意到恒等式

$$\left(\sum_{x \in \mathcal{X}} D^{-l(x)} \right)^k = \sum_{x^k \in \mathcal{X}^k} D^{-l(x_1)} \dots D^{-l(x_k)} = \sum_{x^k \in \mathcal{X}^k} D^{-l(\mathbf{x})}$$

按码字长度合并同类项:

$$\sum_{x^k \in \mathcal{X}^k} D^{-l(\mathbf{x})} = \sum_{m=1}^{kl_{\max}} a_m D^{-m}$$

唯一可译性要求 $a_m \leq D^m$, 于是

$$\sum_{m=1}^{kl_{\max}} a_m D^{-m} \leq kl_{\max}$$

即

$$\sum D^{-l_j} \leq (kl_{\max})^{1/k}$$

令 $k \rightarrow \infty$ 即得。

□

Corollary 4.1.8. 无限信源字母表 $\mathcal{X}$ 的唯一可译码满足 Kraft 不等式。

Proof. 唯一可译码的有限子集仍是唯一可译的。

□

Definition 4.1.7 (信息率). 每传送一个无记忆离散信源符号, 信源编码输出的信息量称为编码器输出的信息率, 记为 R , 对于变长编码, 信息率接近且略小于信源熵, 此时编码称为熵编码。

编码效率定义为

$$\eta = \frac{H(X)}{R}$$

对于变长编码, 编码效率略小于1, 对于等长编码则通常较小。

4.2 Huffman编码

Huffman编码是最优编码的构造算法。给定 D 元字母表 Σ , X 有概率分布 $(p_1, \dots, p_n)$, 重复执行以下步骤:

- ①将概率按降序排列
- ②在这个排列方式中, 选取末尾 D 个字符, 依次赋码字 $0 \sim D-1$
- ③赫夫曼合并(Huffman reduction): 将此 D 个字符视作一个新字符, 概率为各字符概率之和重复到只剩一个字符为止。

Codeword Length	Codeword	X	Probability
2	01	1	0.25
2	10	2	0.25
2	11	3	0.2
3	000	4	0.15
3	001	5	0.15

图 4.1: 赫夫曼编码算法执行例

Remark 4.2.1. ①若 $D \geq 3$, 每一步减少字符数为 $D-1$, 字符总数必为 $1+k(D-1)$. 如果 $|\mathcal{X}|$ 不满足条件, 需要添加概率为0的虚拟字符

②将 p_j 视为权重时可以不要求 $\sum p_j = 1$, 此时同样可以用赫夫曼码最小化码长加权和 $\sum p_j l_j$

③赫夫曼码不唯一。例如


$$D = 2, p = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$$

Codeword	X	Probability
1	1	0.25
2	2	0.25
01	3	0.2
02	4	0.1
000	5	0.1
001	6	0.1
002	Dummy	0.0

图 4.2: $D=3$, 虚拟字符使用例

上图中缩减无兄弟的节点后即得**编码树**（字符对应叶子节点）

Example 4.2.1. 图4.1的编码树为



赫夫曼码是一种最优即时码。最优即时码是在期望长度最小意义下的即时码，它不是唯一的。

Lemma 4.2.1 (最优即时码的刻画). 任给分布 $\mathbf{p}$, $D=2$, 最优即时码必然满足:

- (1) $p_i > p_j \implies l_i \leq l_j$, 即码长与概率反序;
- (2) 最长的两个码字拥有相同的长度, 且对应两个最小可能字符。

此外, 总能构造编码满足下述条件:

- (3) 最长的两个码字仅在最后一位有差别
- 称满足(3)的最优编码是典则的(*canonical*).

Proof. (1)对 $p_i > p_j$, 设编码 C 满足 $l_i \leq l_j$, C' 为 C 交换 i, j 编码所得, 则有

$$\begin{aligned} L(C') - L(C) &= p_j l_i + p_i l_j - p_i l_i - p_j l_j \\ &= (p_j - p_i)(l_i - l_j) \geq 0 \end{aligned}$$

(2)(3)两个最长码字在编码树中对应兄弟节点, 否则必然可以修剪编码树(删除码字最后一位)。□

Remark 4.2.2. (1)赫夫曼码满足

$$H(X) \leq L(C) < H(X) + 1$$

(2)赫夫曼码是贪心算法，即局部最优→全局最优

4.3 其他编码

4.3.1 香农码

前面已经介绍。对于单个字符，赫夫曼码与香农码都可能有更短的码字长度，但平均意义下赫夫曼码才是最优编码。

香农码具有唯一竞争最优性：在单局游戏中，以甲、乙对同一随机序列的编码长短决定胜负，则香农码是一个很好的策略。

以下设 $D=2$ 。

Theorem 4.3.1. (1)设 C 为香农码， C' 为其他唯一可译码，则

$$P\{l(X) \geq l'(X) + c\} \leq \frac{1}{2^{c-1}}$$

(2) (香农码的唯一竞争最优性) 设 $p(x)$ 是二进制的， $l(x) = \log \frac{1}{p(x)}$ 为香农码的码字长度，则

$$\forall C', P\{l(X) < l'(X)\} \geq P\{l(X) > l'(X)\}$$

取等 $\iff \forall x, l(x) = l'(x)$ 。

Corollary 4.3.2. 对于非二进制的 $p(x)$ ，有

$$\mathbb{E} \operatorname{sgn}(l(X) - l'(X) - 1) \leq 0$$

其中 l 为香农码 C 的码字长度。

4.3.2 费纳(Fano)编码

将概率值递减排列，然后选取 k 使得

$$\left| \sum_{i=1}^k p_i - \sum_{i=k+1}^m p_i \right|$$

最小（二分概率），概率高者赋0，概率低者赋1，再对子字符集重复此过程，直到每一字符分得唯一码字。

一般来说，这种编码不是最优编码，但是可以达到 $L(C) \leq H(X) + 2$ 。

4.3.3 Shannon-Fano-Elias编码

考虑累积分布函数 $F(x) = \sum_{a \leq x} p(a)$ 及其修正 $\bar{F}(x)$ ， $\bar{F}(x)$ 在间断点处取左右平均值。

以 $\bar{F}(x)$ 的二进制表示的小数部分作为字符 x 的码字。在码字无限时，取前 $\left\lceil \log \frac{1}{p(x)} \right\rceil + 1$ 位即可。

编码的唯一性：以 $\lfloor \bar{F}(x) \rfloor_{l(x)}$ 记 $\bar{F}(x)$ 保留 $l(x)$ 位。取 $l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil + 1$ ，则

$$F(x) - \lfloor \bar{F}(x) \rfloor_{l(x)} < \frac{1}{2^{l(x)}} < \frac{1}{2} 2^{\log p(x)} = \frac{p(x)}{2}$$

即 $\lfloor \bar{F}(x) \rfloor_{l(x)}$ 在 $F(x)$ 下方跳变幅度以内，对应了唯一的区间。

这种编码的特点是：应用广泛； $L(C) < H(X) + 2$ ；必为前缀码（考虑区间树可证）

第五章 信道容量

5.1 通信系统模型

Definition 5.1.1 (信源模型). (1)根据信源输出信号所对应的随机过程是否平稳, 分为**稳恒(平稳)信源**和**非稳恒(非平稳)信源**
(2)根据特殊的随机过程类型, 分为**高斯信源**、**Markov信源**等
(3)信源字母表离散, 信号取值时刻离散的稳恒信源称为**离散稳恒信源**

Definition 5.1.2 (信道模型). (1)按输入输出信号在幅值和时间上的取值分为**离散信道(数字信道)**、**连续信道**等
离散信道(discrete channel)是至多可数的输入字母表 $\mathcal{X}$ 和输出字母表 $\mathcal{Y}$, 及 $\mathcal{X}$ 到 $\mathcal{Y}$ 的转移概率模型构成的系统
(2)如果信道输出值域信道在该时刻的输入有关, 二与先前的输入输出等无关, 则信道是**无记忆信道(memoryless channel)**; 否则为**有记忆信道**
(3)按输入输出信号之间的关系是否确定, 分为**有噪信道**和**无噪信道**等

Definition 5.1.3 (离散无记忆信道). 离散无记忆信道(DMC)的转移概率模型可以用转移概率分布 $p(y|x)$ 描述。
设输入字母表为 $\mathcal{X}$, 输出字母表为 $\mathcal{Y}$, 该DMC可以用

$$(\mathcal{X}, p(x|y), \mathcal{Y})$$

表示

离散无记忆信道的n次扩展可以用

$$(\mathcal{X}^n, p(x^n|y^n), \mathcal{Y}^n)$$

表示, 其中

$$p(y_k|x^k, y^{k-1}) = p(y_k|x_k), \forall k \in \{1, 2, \dots, n\}$$

进一步, 如果信道不带反馈(如不明确指出, 则默认不带反馈), 即输入字符不依赖于过去的输出字符, 即

$$p(x_k|x^{k-1}, y^{k-1}) = p(x_k|x^{k-1}), \forall k$$

则n次扩展的信道转移函数简化为

$$p(y^k|x^k) = \prod_{i=1}^k p(y_i|x_i), \forall k$$

Definition 5.1.4 (信息信道容量). 离散无记忆信道的**信息信道容量**(information channel capacity)定义为

$$C = \max_{p(x)} I(X; Y)$$

香农第二定理将指出信息信道容量=信道容量=信道最高码率=任意小误差传输比特数/信道使用次数。

$I(X; Y)$ 关于输入分布 $p(x)$ 是紧集上的连续的凹函数, 因此最大值存在且唯一, 使用max是合理的。

Proposition 5.1.1 (信息信道容量的性质).

- $C \geq 0$, 取等 $\iff$ 信道输出与输入独立
- $C \leq \log |\mathcal{X}|$, 取等 $\iff X, Y$ 独立且 $X \sim U_{\mathcal{X}}$
- $C \leq \log |\mathcal{Y}|$, 取等 $\iff$ 存在输入分布使得输出分布为均匀分布

Definition 5.1.5 (对称信道). 如果离散无记忆信道的概率转移矩阵 $p(x|y)$ 是**数独矩阵**, 则称该信道为**对称信道**(symmetric channel)。数独矩阵必然是双随机。

数独矩阵可以描述为: 任何两行互为置换、任何两列也互为置换。

如果每一行 $p(\cdot|x)$ 都是同一分布的置换, 且所有列的元素和 $\sum_x p(y|x)$ 相同, 则该信道是**弱对称信道**(weakly symmetric channel)

Theorem 5.1.2. 对于弱对称信道, 信息信道容量为

$$C = \log |\mathcal{Y}| - H(p(\cdot|x))$$

其中 $p(\cdot|x)$ 为任一行的分布。取等 $\iff$ 输入分布为均匀分布

Example 5.1.1 (有噪打字机信道). 该种信道的概率转移矩阵矩阵的基本特征是, 对角线元素(不出错的概率)接近于1, 除了对角线, 每一行都有个别元素数值较大, 而其他元素极小或为0。描述了考虑失误的打字机。

输入、输出字母表相同, 输入以0.5的概率被输出端无改变地接收, 以0.5的概率变为下一个字母。字母表大小为26时, $C = 13\text{bit}/\text{传输}$:

一方面, 每次传输可以无误差地传输其中13个字符(仅传输奇数位置或偶数位置的字符); 另一方面,

$$C = \max I(X; Y) = \max [H(Y) - H(Y|X)] = \max H(Y) - 1 = \log 26 - 1 = \log 13\text{bit}/\text{传输}$$

取等 $\iff p(x) \sim U$




图 5.1: 离散通信信道模型

信源编码和信道编码，是通信系统的两个核心模块，目标完全不同。简单来说：

- **信源编码负责压缩**，目标是**高效**。
- **信道编码负责保护**，目标是**可靠**。

它们的核心区别体现在以下几个方面：

1. 目标不同

- **信源编码**：旨在**去除冗余**，将数据尽可能地压缩。就好像要把行李箱里的空气挤掉，用最小的空间装东西。
- **信道编码**：旨在**增加冗余**，通过添加校验信息来对抗传输中的干扰和错误。这就像在易碎品周围填充泡沫，虽然体积变大了，但能保证货物安全到达。

2. 输入输出不同

- **信源编码**：输入是原始数据（如语音、图像），输出是**压缩后的比特流**。它是一个“数据专用”的模块，比如MP3、JPEG就是信源编码。
- **信道编码**：输入就是信源编码后的比特流，输出是**长度更长、有规律的码字**。它是一个“比特流专用”的模块，比如无线通信中的Turbo码、LDPC码。

3. 处理对象不同

- **信源编码**：处理的是**信源符号的统计特性**。比如，给常出现的符号分配短码字（霍夫曼编码），或去除相邻像素的相关性。
- **信道编码**：处理的是**信道的噪声特性**。它根据信道的干扰模式（如随机错或突发错）来设计保护方案。

4. 关注指标不同

- **信源编码**：关注**压缩率** ($R = \frac{\log M}{n}$)，目标是让码率尽可能接近信源的熵 $H(S)$ 。压缩率越高，信息密度越大。
- **信道编码**：关注**纠错能力和码率**，目标是让传输的码率尽可能接近**信道容量** C ，同时保证错误概率任意小。

5. 核心定理不同

- **信源编码**：遵循**香农第一定理**（无失真信源编码定理），指出**压缩的极限是信源的熵** $H(S)$ 。低于这个极限，信息就无法无损还原。
- **信道编码**：遵循**香农第二定理**（有噪信道编码定理），指出**可靠传输的极限是信道容量** C 。只要码率低于 C ，就能实现可靠通信。

图 5.2: 信源编码与信道编码的关系

Definition 5.1.6 ((M, n) 码). 信道 $(\mathcal{X}, p(y|x), \mathcal{Y})$ 的 (M, n) 码由以下部分构成：

- 指标集 $\{1, 2, \dots, M\}$

- 编码函数(encoding function)

$$x^n : \{1, 2, \dots, M\} \rightarrow \mathcal{X}^n$$

生成码字(codewords) $x^n(1), x^n(2), \dots, x^n(M)$, 所有码字的集合称为码本(code-book)

$$\mathcal{C} = \{x^n(1), x^n(2), \dots, x^n(M)\} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_M\}$$

- 译码函数

$$g : \mathcal{Y}^n \rightarrow \{1, 2, \dots, M\}$$

Definition 5.1.7 (条件误差概率). 已知指标 i 被发送, (给定发送符号时的) 条件误差概率(conditional probability of error)为

$$\lambda_i = P\{g(Y^n) \neq i | X^n = x^n(i)\}$$

它衡量了特定符号在传输过程中的脆弱性或抗干扰能力。

已知接收到符号 y , (给定接收符号时的) 条件误差概率为

$$1 - \max_x P\{X = x | Y = y\}$$

反映了收到特定 y 后, 接收端对这次判决的不确定性。条件误差概率通常指前者。

Definition 5.1.8. (M, n) 码的最大误差概率(maximum probability of error)为

$$\lambda^{(n)} = \max_{i \in \{1, 2, \dots, M\}} \lambda_i$$

(算数) 平均误差概率(average probability of error)为

$$P_e^{(n)} = \bar{\lambda} = \frac{1}{M} \sum_{i=1}^M \lambda_i$$

Remark 5.1.1. 如果指标 W 的选取服从均匀分布, 则 $P_e^{(n)} = P\{W \neq g(Y^n)\}$ 。

Remark 5.1.2. 显然, $P_e^{(n)} \leq \lambda^{(n)}$ 。理应希望这二者差异大, 但将证明: 在相同码率下, 平均误差概率小 $\implies$ 最大误差概率小

码率衡量了每个信道符号能够传输的平均信息量:

Definition 5.1.9 (码率). (M, n) 码的码率(rate)为

$$R = \frac{\log M}{n} (\text{bit/传输})$$

如果存在一个 $([2^{nR}], n)$ 码, 满足 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$, 则称码率 R 是可达的(achievable)。一般将此编码简记为 $(2^{nR}, n)$ 。

信道容量定义为可达码率的上确界。

5.2 联合典型序列

Definition 5.2.1 (联合典型序列). 服从分布 $p(x, y)$ 的联合典型序列(jointly typical sequence) $\{(x^n, y^n)\}$ 所构成的集合 $A_\epsilon^{(n)}$ 是指其经验熵与真实熵以 ϵ 为界靠近的 n 长序列构成的集合, 即:

$$A_\epsilon^{(n)} = \{(x^n, y^n) \in \mathcal{X}^n \times \mathcal{Y}^n : \begin{aligned} &\left| -\frac{1}{n} \log p(x^n) - H(X) \right| < \epsilon, \\ &\left| -\frac{1}{n} \log p(y^n) - H(Y) \right| < \epsilon, \\ &\left| -\frac{1}{n} \log p(x^n, y^n) - H(X, Y) \right| < \epsilon \end{aligned}\}$$

其中

$$p(x^n, y^n) = \prod_{i=1}^n p(x_i, y_i)$$

定义包括单独典型+联合典型, 即单独出现概率高, 且联合出现被认为是合理的。

Theorem 5.2.1 (联合AEP). 设 (X^n, Y^n) 为服从 $p(x^n, y^n) = \prod_{i=1}^n p(x_i, y_i)$ 的*i.i.d.*的 n 长序列, 则

① $P\{(X^n, Y^n) \in A_\epsilon^{(n)}\} \rightarrow 1, n \rightarrow \infty$

② $|A_\epsilon^{(n)}| \leq 2^{n(H(X, Y) + \epsilon)}$

③ 如果 $(\tilde{X}^n, \tilde{Y}^n) \sim p(x^n)p(y^n)$ (i.e. $\tilde{X}^n$ 与 $\tilde{Y}^n$ 独立且具有 $p(x^n, y^n)$ 的边界分布, 与 X^n, Y^n 分别同分布), 则

$$P\{(\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)}\} \leq 2^{-n(I(X; Y) - 3\epsilon)}$$

且对于充分大的 n , 有

$$P\{(\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)}\} \geq (1 - \epsilon)2^{-n(I(X; Y) + 3\epsilon)}$$

Proof. ①由弱大数定律,

$$-\frac{1}{n} \log p(X^n) \rightarrow -\mathbb{E} \log p(X) = H(X) \quad \text{依概率}$$

故 $\forall \epsilon > 0, \exists n_1, n > n_1$ 时, 有

$$P\left\{\left| -\frac{1}{n} \log p(X^n) - H(X) \right| \geq \epsilon\right\} < \frac{\epsilon}{3}$$

同理,

$$-\frac{1}{n} \log p(Y^n) \rightarrow -\mathbb{E} \log p(Y) = H(Y) \quad \text{依概率}$$

$$-\frac{1}{n} \log p(X^n, Y^n) \rightarrow -\mathbb{E} \log p(X, Y) = H(X, Y) \quad \text{依概率}$$

从而有 n_2, n_3 ,

$$n > n_2 \implies P\left\{\left| -\frac{1}{n} \log p(Y^n) - H(Y) \right| \geq \epsilon\right\} < \frac{\epsilon}{3}$$

$$n > n_3 \implies P \left\{ \left| -\frac{1}{n} \log p(X^n, Y^n) - H(X, Y) \right| \geq \epsilon \right\} < \frac{\epsilon}{3}$$

取 $n > \max\{n_1, n_2, n_3\}$, 则

$$P\{(X^n, Y^n) \in A_\epsilon^{(n)}\} > 1 - \epsilon$$

②注意到

$$\begin{aligned} 1 &= \sum p(x^n, y^n) \\ &\geq \sum_{A_\epsilon^{(n)}} p(x^n, y^n) \\ &\geq |A_\epsilon^{(n)}| \cdot 2^{-n(H(X, Y) + \epsilon)} \end{aligned}$$

这与要证的式子是等价的。最后一行成立是因为，根据 $A_\epsilon^{(n)}$ 的定义（最后一条），每个 $A_\epsilon^{(n)}$ 的元素 (x^n, y^n) 都满足

$$-n(H(X, Y) + \epsilon) < \log p(x^n, y^n) < -n(H(X, Y) - \epsilon)$$

③在这种假设下，有

$$\begin{aligned} P\left\{\left(\tilde{X}^n, \tilde{Y}^n\right) \in A_\epsilon^{(n)}\right\} &= \sum_{(x^n, y^n) \in A_\epsilon^{(n)}} p(x^n) p(y^n) \\ &\leq 2^{n(H(X, Y) + \epsilon)} \cdot 2^{-n(H(X) - \epsilon)} \cdot 2^{-n(H(Y) - \epsilon)} \\ &= 2^{-n(I(X; Y) - 3\epsilon)} \end{aligned}$$

在 n 充分大时， $P\left\{\left(\tilde{X}^n, \tilde{Y}^n\right) \in A_\epsilon^{(n)}\right\} \geq 1 - \epsilon$ ，因此

$$\begin{aligned} 1 - \epsilon &\leq \sum_{(x^n, y^n) \in A_\epsilon^{(n)}} p(x^n, y^n) \\ &\leq |A_\epsilon^{(n)}| \cdot 2^{-n(H(X, Y) - \epsilon)} \end{aligned}$$

即证后一不等式。 □

5.3 信道编码定理

Theorem 5.3.1 (信道编码定理/香农第二定理). 对于离散无记忆信道，小于信道容量 C 的所有码率都是可达的，即 $\forall R < C$ ，存在 $(2^{nR}, n)$ 码使得最大误差概率 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ ；反之，任何满足 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ 的 $(2^{nR}, n)$ 码必然满足 $R \leq C$ 。

P115页，原定理证明的表述看不懂，只给逆定理。

Lemma 5.3.2 (Fano不等式). 设离散无记忆信道的码本为 C ，输入消息 W 服从均匀分布，则

$$H(W|\hat{W}) \leq 1 + P_e n R$$

Proof. 由于 W 服从均匀分布, 有

$$P_e^{(n)} = P\{W \neq \hat{W}\}$$

定义指示变量 $E = \mathbf{1}\{W \neq \hat{W}\}$, 则用Fano不等式,

$$\begin{aligned} H(W|\hat{W}) &= H(W, E|\hat{W}) \\ &= H(E|\hat{W}) + H(W|E, \hat{W}) \\ &\leq H(E) + P_e^{(n)} \log M \\ &\leq 1 + P_e^{(n)} nR \end{aligned}$$

□

多次使用离散无记忆信道, 容量是线性的:

Lemma 5.3.3. 设 Y^n 为 X^n 经过容量为 C 的离散无记忆信道传输所得的输出信号, 则

$$I(X^n; Y^n) \leq nC, \forall p(x^n)$$

Proof. 已知 Y_k 仅依赖于 X_k 而与其他输入条件独立, 因此有

$$\begin{aligned} I(X^n; Y^n) &= H(Y^n) - H(Y^n|X^n) \\ &= H(Y^n) - \sum_{k=1}^n H(Y_k|Y_1, \dots, Y_{k-1}, X^n) \\ &= H(Y^n) - \sum_{k=1}^n H(Y_k|X_k) \\ &\leq \sum_{k=1}^n H(Y_k) - \sum_{k=1}^n H(Y_k|X_k) \\ &= \sum_{k=1}^n I(X_k; Y_k) \\ &\leq nC \end{aligned}$$

其中第一个不等号可以由熵的链式法则+“条件熵 $\leq$ 熵”得到。

□

Theorem 5.3.4 (信道编码定理的弱逆定理). 设 W 服从均匀分布, 则任意满足 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ 的 $(2^{nR}, n)$ 码必然满足 $R \leq C$ 。

Proof. 给定编码规则 $x^n(\cdot)$ 和译码规则 $\hat{W} = g(Y^n)$, 有Markov链

$$W \rightarrow X^n \rightarrow Y^n \rightarrow \hat{W}$$

因此

$$\begin{aligned} nR &= H(W) && (W \sim U_{\{1,2,\dots,2^{nR}\}}) \\ &= I(W; \hat{W}) + H(W|\hat{W}) \\ &\leq I(X^n; Y^n) + 1 + P_e^{(n)} nR && (\text{数据处理+Fano}) \\ &\leq nC + 1 + P_e^{(n)} nR && (\text{前一引理}) \end{aligned}$$

即

$$R \leq C + \frac{1}{n} + P_e^{(n)} R$$

令 $n \rightarrow \infty$, $\lambda^{(n)} \rightarrow 0 \implies P_e^{(n)} \rightarrow 0$, 从而 $R \leq C$ 。 $\square$

以上证明还能顺便得到

$$P_e^{(n)} \geq 1 - \frac{C}{R} - \frac{1}{nR}$$

因此当 $R > C$ 时, $P_e^{(n)} \rightarrow 1, n \rightarrow \infty$, 从而对于所有的 n , 误差概率无法充分接近 0, 否则串联这些短码可使 $P_e^{(n)}$ 充分接近 0。

Theorem 5.3.5 (信道编码定理的强逆定理). 设 W 服从均匀分布, 如果码率 $R > C$, 则对于任意 $(2^{nR}, n)$ 码, 最大误差概率 $\lambda^{(n)} \rightarrow 1, n \rightarrow \infty$ (以指数级); 反之, 如果 $R < C$, 则存在 $(2^{nR}, n)$ 码使得 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ (以指数级)。

5.4 反馈容量

Definition 5.4.1 (反馈码). $(2^{nR}, n)$ 反馈码的编码函数为

$$x_k : \{1, 2, \dots, 2^{nR}\} \times \mathcal{Y}^{k-1} \rightarrow \mathcal{X}, \forall k \in \{1, 2, \dots, n\}$$

它与消息 W 和之前的输出 $Y_1, \dots, Y_{k-1}$ 相关。译码函数同前。




图 5.3: 带反馈的离散通信信道模型

当 $W \sim U_{\{1, 2, \dots, 2^{nR}\}}$ 时, $(2^{nR}, n)$ 反馈码的平均误差概率为

$$P_e^{(n)} = P\{W \neq g(Y^n)\}$$

Definition 5.4.2 (带反馈容量). 离散无记忆信道的带反馈容量(feedback capacity) C_{FB} 定义为可达反馈码率的上确界, 即存在 $(2^{nR}, n)$ 反馈码使得 $P_e^{(n)} \rightarrow 0, n \rightarrow \infty$ 的最大 R 。

引入反馈无法增加信道容量:

Theorem 5.4.1 (反馈容量). 设 W 服从均匀分布, 则离散无记忆信道的带反馈容量等于其信息信道容量, 即 $C_{FB} = C$ 。

Proof. 类似弱逆定理的证明,

$$nR = H(W) = H(W|\hat{W}) + I(W; \hat{W})$$

$$\begin{aligned} &\leq 1 + P_e^{(n)} nR + I(W; \hat{W}) && (\text{lemma:Fano不等式}) \\ &\leq 1 + P_e^{(n)} nR + I(W; Y^n) && (\text{数据处理不等式}) \end{aligned}$$

下面估计 $I(W; Y^n)$ ，由于 Y_k 仅依赖于 X_k 而与其他输入条件独立，因此

$$\begin{aligned} I(W; Y^n) &= H(Y^n) - H(Y^n|W) \\ &= H(Y^n) - \sum_{k=1}^n H(Y_k|Y_1, \dots, Y_{k-1}, W) \\ &= H(Y^n) - \sum_{k=1}^n H(Y_k|Y_1, \dots, Y_{k-1}, W, X_k) && (X_k \text{ 是 } Y_1, \dots, Y_{k-1}, W \text{ 的函数}) \\ &= H(Y^n) - \sum_{k=1}^n H(Y_k|X_k) && (\text{条件独立性}) \\ &\leq \sum_{k=1}^n H(Y_k) - \sum_{k=1}^n H(Y_k|X_k) \\ &= \sum_{k=1}^n I(X_k; Y_k) \\ &\leq nC \end{aligned}$$

从而

$$R \leq C + \frac{1}{n} + P_e^{(n)} R$$

令 $n \rightarrow \infty$, $\lambda^{(n)} \rightarrow 0 \implies P_e^{(n)} \rightarrow 0$, 从而 $R \leq C$ 。 □

不过，反馈能够简化编码和译码。

5.5 信源信道分离定理

通过信道发送字符序列 $V^n = V_1, V_2, \dots, V_n$ ，希望保证接收者可以重构序列。为此将序列映射成码字 $X^n(V^n)$ ，通过信道发送码字，接收者得到 Y^n ，给出发送序列 V^n 的估计 $\hat{V}^n = g(Y^n)$ 。

Definition 5.5.1 (误差概率). 定义误差概率为：

$$P\{V^n \neq \hat{V}^n\} = \sum_{y^n} \sum_{v^n} p(v^n) p(y^n | x^n(v^n)) I\{v^n \neq \hat{v}^n(y^n)\}$$

其中 I 为示性函数， $g(y^n)$ 为译码函数

系统如下图：




图 5.4: 联合信源信道编码

Theorem 5.5.1 (信源信道编码定理). 设 $V_1, \dots, V_n$ 为有限字母表上满足 AEP (将证明平稳遍历信源均满足 AEP) 和 $H(\mathcal{V}) < C$ 的随机过程, 则存在一个信源信道编码使得误差概率 $P\{V^n \neq \hat{V}^n\} \rightarrow 0, n \rightarrow \infty$; 反之, 对任意平稳随机过程, 如果 $H(\mathcal{V}) > C$, 则对于任意信源信道编码, 误差概率 $P\{V^n \neq \hat{V}^n\} \rightarrow 1, n \rightarrow \infty$, 从而不可能以任意低误差概率通过信道发送该过程。

Proof. (1) 可达性: 两步骤编码

AEP $\implies \exists$ 典型集 $A_\epsilon^{(n)}$, 满足 $|A_\epsilon^{(n)}| \leq 2^{n(H(\mathcal{V})+\epsilon)}$ 且 $P\{V^n \in A_\epsilon^{(n)}\} \rightarrow 1, n \rightarrow \infty$, 则典型集外的所有序列产生一个错误, 对误差概率的贡献不超过 ϵ 。

用 $n(H + \epsilon)$ bit 给典型集中的序列编号。可以以低于 ϵ 的误差概率发送这些编号, 如果

$$H(\mathcal{V}) + \epsilon = R < C$$

信宿可以通过枚举典型集 $A_\epsilon^{(n)}$ 中的序列, 并选择与被估计编号对应的序列 (根据典型性) 来重构输入序列, 从而以误差概率不超过 ϵ 的方式发送输入序列。具体来说, n 充分大时, 有

$$P\{V^n \neq \hat{V}^n\} \leq P\{V^n \notin A_\epsilon^{(n)}\} + P\{\hat{V}^n \neq V^n | V^n \in A_\epsilon^{(n)}\} \leq 2\epsilon$$

因此, 只要 $H(\mathcal{V}) < C$, 就可以找到足够大的 n 使得能够以任意小的误差概率通过信道发送输入序列。

(2) 逆定理

希望证明, 对于任意信源信道编码序列

$$X^n(V^n) : \mathcal{V}^n \rightarrow \mathcal{X}^n$$

$$g_n : \mathcal{Y}^n \rightarrow \mathcal{V}^n$$

都有 $P\{V^n \neq \hat{V}^n\} \rightarrow 0 \implies H(\mathcal{V}) \leq C$ 。其中 X^n 为信源数据序列 V^n 的任意码字分配函数, g_n 为任意译码函数。

有 Markov 链

$$V^n \rightarrow X^n \rightarrow Y^n \rightarrow \hat{V}^n$$

由 Fano 不等式,

$$\begin{aligned} H(V^n | \hat{V}^n) &\leq 1 + P\{V^n \neq \hat{V}^n\} \log |\mathcal{V}^n| \\ &= 1 + nP\{V^n \neq \hat{V}^n\} \log |\mathcal{V}| \end{aligned}$$

因此

$$\begin{aligned} H(\mathcal{V}) &\leq \frac{H(V_1, \dots, V_n)}{n} = \frac{H(V^n)}{n} && \text{(平稳过程的熵率定义)} \\ &= \frac{H(V^n | \hat{V}^n)}{n} + \frac{I(V^n; \hat{V}^n)}{n} \\ &\leq \frac{1}{n} + P\{V^n \neq \hat{V}^n\} \log |\mathcal{V}| + \frac{I(X^n; Y^n)}{n} && \text{(Fano+数据处理)} \\ &\leq \frac{1}{n} + P\{V^n \neq \hat{V}^n\} \log |\mathcal{V}| + C && \text{(信道的无记忆性)} \end{aligned}$$

令 $n \rightarrow \infty$, $P\{V^n \neq \hat{V}^n\} \rightarrow 0$, 从而 $H(\mathcal{V}) \leq C$ 。 □

分离定理表明，下图的分离编码器与前面的联合编码器能达到相同的码率，因此可以将信源编码和信道编码分开设计，信源编码器负责找到信源的最有效表示，信道编码器要使编码消息具备能对抗信道中的噪声和错误的的能力。




图 5.5: 分离信源信道编码

第六章 微分熵

6.1 微分熵

在概率密度函数存在时，定义：

Definition 6.1.1 (微分熵). 设连续随机变量 X 的概率密度函数为 $f(x)$ ，则 X 的微分熵(differential entropy)定义为

$$h(X) = h(f) = - \int f(x) \log f(x) dx = \mathbb{E} \log \frac{1}{f(X)}$$

微分熵可能为负。例如均匀分布 $X \sim U(a, b)$ ， $h(X) = \log(b - a)$ 。

Definition 6.1.2 (联合微分熵). 设连续随机变量 $(X_1, \dots, X_n)$ 的联合概率密度函数为 $f(x_1, \dots, x_n)$ ，则 $(X_1, \dots, X_n)$ 的联合微分熵定义为

$$h(X_1, \dots, X_n) = - \int f(x^n) \log f(x^n) dx^n = \mathbb{E} \log \frac{1}{f(X^n)}$$

Definition 6.1.3 (条件微分熵). 设连续随机变量 (X, Y) 的联合概率密度函数为 $f(x, y)$ ，则 X 在已知 Y 的条件下的条件微分熵定义为

$$h(X|Y) = - \int \int f(x, y) \log f(x|y) dx dy = \mathbb{E} \log \frac{1}{f(X|Y)}$$

其中

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}$$

为条件概率密度函数。由此,在不涉及积分发散的前提下，有：

$$h(X|Y) = h(X, Y) - h(Y)$$

条件微分熵是取条件于 Y 所得的微分熵：

$$h(X|Y = y) = - \int f(x|y) \log f(x|y) dx$$

$$h(X|Y) = \int f_Y(y) h(X|Y = y) dy = \mathbb{E}[h(X|Y = y)]$$

Example 6.1.1 (多元正态分布的熵). 设 $X_1, \dots, X_n$ 服从均值为 μ , 协方差矩阵为 K 的多元正态分布, 则

$$h(X_1, \dots, X_n) = \frac{1}{2} \log((2\pi e)^n |K|)$$

证明: 联合概率密度函数为

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |K|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T K^{-1}(\mathbf{x} - \mu)\right)$$

由定义,

$$\begin{aligned} h(X_1, \dots, X_n) &= - \int f(\mathbf{x}) \left[-\frac{1}{2}(\mathbf{x} - \mu)^T K^{-1}(\mathbf{x} - \mu) - \frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln |K| \right] d\mathbf{x} \\ &= \frac{1}{2} \int f(\mathbf{x}) (\mathbf{x} - \mu)^T K^{-1}(\mathbf{x} - \mu) d\mathbf{x} + \frac{1}{2} \ln(2\pi)^n |K| \\ &= n + \frac{1}{2} \ln(2\pi)^n |K| \\ &= \frac{1}{2} \ln((2\pi e)^n |K|) \text{ (奈特)} \\ &= \frac{1}{2} \log((2\pi e)^n |K|) \text{ (比特)} \end{aligned}$$

其中,

$$\begin{aligned} \int f(\mathbf{x}) (\mathbf{x} - \mu)^T K^{-1}(\mathbf{x} - \mu) d\mathbf{x} &= \mathbb{E} \left[\sum_{i,j} (X_i - \mu_i) (K^{-1})_{ij} (X_j - \mu_j) \right] \\ &= \sum_{i,j} (K^{-1})_{ij} \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)] \\ &= \sum_{i,j} (K^{-1})_{ij} K_{ji} \\ &= \text{tr}(K^{-1}K) \\ &= n \end{aligned}$$

Definition 6.1.4 (相对熵). 两个概率密度函数 $f(x)$ 和 $g(x)$ 的**相对熵**(relative entropy)定义为

$$D(f||g) = \int f(x) \log \frac{f(x)}{g(x)} dx = \mathbb{E}_f \log \frac{f(X)}{g(X)}$$

仅当 $\text{supp}(f) \subseteq \text{supp}(g)$, 即 $g = 0 \implies f = 0$ 时, $D(f||g)$ 有限。

Definition 6.1.5 (互信息). 设连续随机变量 (X, Y) 的联合概率密度函数为 $f(x, y)$, 则 X 与 Y 的**互信息**定义为

$$I(X; Y) = \int \int f(x, y) \log \frac{f(x, y)}{f(x)f(y)} dx dy = \mathbb{E} \log \frac{f(X, Y)}{f(X)f(Y)}$$

由定义,

$$I(X; Y) = D(f(x, y) || f(x)f(y))$$

$$\begin{aligned}
I(X; Y) &= h(X) - h(X|Y) \\
&= h(Y) - h(Y|X) \\
&= h(X) + h(Y) - h(X, Y)
\end{aligned}$$

6.2 连续随机变量的AEP

Definition 6.2.1 (典型集). $\forall \epsilon > 0, n \in \mathbb{N}^+$, 定义连续随机变量 $X \sim f(x)$ 的典型集为

$$A_\epsilon^{(n)} = \left\{ x^n \in \mathbb{R}^n : \left| -\frac{1}{n} \log f(x^n) - h(X) \right| < \epsilon \right\}$$

其中

$$f(x^n) = \prod_{i=1}^n f(x_i)$$

以 $\text{Vol}(A)$ 表示集合 A 的体积, 则有以下连续版本的AEP:

Theorem 6.2.1 (连续版本的AEP). 设 $X_1, X_2, \dots, X_n$ 为 *i.i.d.* 的连续随机变量, 且 $X_i \sim f(x)$, 则

- 对充分大的 n , 有 $P\{X^n \in A_\epsilon^{(n)}\} > 1 - \epsilon$
- $\forall n, \text{Vol}(A_\epsilon^{(n)}) \leq 2^{n(h(X)+\epsilon)}$
- 对充分大的 n , 有 $\text{Vol}(A_\epsilon^{(n)}) \geq (1 - \epsilon)2^{n(h(X)-\epsilon)}$

Proof. 由弱大数定律,

$$-\frac{1}{n} \log f(X^n) \rightarrow -\mathbb{E} \log f(X) = h(X) \quad \text{依概率}$$

从而 $\forall \epsilon > 0, \exists N$, 当 $n > N$ 时, 有

$$P\left\{ \left| -\frac{1}{n} \log f(X^n) - h(X) \right| \geq \epsilon \right\} \leq \epsilon$$

此即性质1.

由于

$$\begin{aligned}
1 &= \int f(x^n) dx^n \\
&\geq \int_{A_\epsilon^{(n)}} f(x^n) dx^n \\
&\geq \text{Vol}(A_\epsilon^{(n)}) \cdot 2^{-n(h(X)+\epsilon)}
\end{aligned}$$

从而性质2成立。其中, $f(x^n)$ 的下界得自典型集的定义:

$$\begin{aligned}
&-n(h(X) + \epsilon) < \log f(x^n) < -n(h(X) - \epsilon) \\
\iff &2^{-n(h(X)+\epsilon)} < f(x^n) < 2^{-n(h(X)-\epsilon)}, \forall x^n \in A_\epsilon^{(n)}
\end{aligned}$$

对于 $n > N$, 有

$$\begin{aligned} 1 - \epsilon &\leq \int_{A_\epsilon^{(n)}} f(x^n) dx^n \\ &\leq \text{Vol}(A_\epsilon^{(n)}) \cdot 2^{-n(h(X) - \epsilon)} \end{aligned}$$

从而性质3成立。 □

Theorem 6.2.2. 在一阶指数意义下, 所有概率 $\geq 1 - \epsilon$ 的集合中, $A_\epsilon^{(n)}$ 的体积最小。

占有大部分概率的最小集合, 体积约为 $2^{nh(X)}$ 。由于 X_k i.i.d., 典型集是 n 维正方体, 边长约为 $2^{h(X)}$ 。这是微分熵的一种解释: 熵是拥有大部分概率的最小集的边长值。

较低微分熵意味着正方形较小, 而较高的熵意味着随机变量高度分散。

6.3 微分熵与离散熵的关系

1. 微分熵

将 $X \sim f(x)$ 的连续随机变量进行量化, 量化长度为 Δ , 得到离散随机变量 X_Δ , 定义为:

$$X_\Delta = x_k, k\Delta \leq X < (k+1)\Delta$$

其中 x_k 为满足

$$f(x_k)\Delta = \int_{k\Delta}^{(k+1)\Delta} f(x)dx$$

的值。

其概率质量函数为

$$p_k = P(X_\Delta = k\Delta) = \int_{k\Delta}^{(k+1)\Delta} f(x)dx = f(x_k)\Delta$$

熵为

$$\begin{aligned} H(X_\Delta) &= - \sum_k p_k \log p_k \\ &= - \sum_k f(x_k)\Delta \log(f(x_k)\Delta) \\ &= - \sum_k f(x_k)\Delta \log f(x_k) - \sum_k f(x_k)\Delta \log \Delta \\ &= - \sum_k f(x_k) \log f(x_k)\Delta - \log \Delta \end{aligned}$$

在 $f(x) \log f(x)$ 黎曼可积, 且量化长度 $\Delta \rightarrow 0$ 时,

$$\begin{aligned} H(X_\Delta) + \log \Delta &= - \sum_k f(x_k) \log f(x_k)\Delta \\ &\rightarrow - \int f(x) \log f(x) dx \\ &= h(X) \end{aligned}$$

于是, 连续型随机变量进行 n 比特均匀量化处理, 量化长度为 $\Delta = 2^{-n}$, 得到的离散随机变量的熵满足

$$H(X_\Delta) = h(X) + n$$

在精确到 n 位的意义下, $h(X) + n$ 是描述 X 所需的平均比特数。

2. 互信息

两个随机变量之间的互信息是经过均匀量化的随机变量之间的互信息的极限:

$$I(X_\Delta; Y_\Delta) = H(X_\Delta) - H(X_\Delta|Y_\Delta) \approx (h(X) - \log \Delta) - (h(X|Y) - \log \Delta) = I(X; Y)$$

更一般地, 设 $\mathcal{P}, \mathcal{Q}$ 分别为 X 和 Y 的所有可能的量化方案 (有限划分方式), $\mathcal{X} = \sqcup_k P_k$, $\mathcal{Y} = \sqcup_l Q_l$, 对应的离散型随机变量为 $[X]_{\mathcal{P}}$, $[Y]_{\mathcal{Q}}$, 定义

$$P\{[X]_{\mathcal{P}} = k\} = \int_{P_k} dF(x), \quad P\{[Y]_{\mathcal{Q}} = l\} = \int_{Q_l} dF(y)$$

则

$$I(X; Y) = \sup_{\mathcal{P}, \mathcal{Q}} I([X]_{\mathcal{P}}; [Y]_{\mathcal{Q}})$$

因为在加密分割下, $I([X]_{\mathcal{P}}; [Y]_{\mathcal{Q}})$ 递增趋于 $I(X; Y)$ 。

6.4 微分熵, 相对熵与互信息的性质

Theorem 6.4.1.

$$D(f||g) \geq 0$$

取等 $\iff f = g, a.e.$

Proof. 记 $\text{supp}(f) = S$, 则

$$\begin{aligned} D(f||g) &= \int_S f(x) \log \frac{f(x)}{g(x)} dx \\ &\geq \log \int_S f(x) \frac{g(x)}{f(x)} dx && (Jensen) \\ &= \log \int_S g(x) dx \\ &= \log 1 \\ &= 0 \end{aligned}$$

□

Corollary 6.4.2.

$$I(X; Y) \geq 0$$

取等 $\iff X$ 独立于 Y

Corollary 6.4.3.

$$h(X|Y) \leq h(X)$$

取等 $\iff X$ 独立于 Y **Theorem 6.4.4** (微分熵的链式法则).

$$h(X_1, \dots, X_n) = \sum_{k=1}^n h(X_k | X_1, \dots, X_{k-1})$$

Corollary 6.4.5.

$$h(X_1, \dots, X_n) \leq \sum_{k=1}^n h(X_k)$$

取等 $\iff X_1, \dots, X_n$ 相互独立

随机变量的平移与伸缩:

Theorem 6.4.6.

$$h(X) = h(X + c), \forall c \in \mathbb{R}$$

Theorem 6.4.7.

$$h(aX) = h(X) + \log |a|, \forall a \in \mathbb{R} \setminus \{0\}$$

Proof. $Y = aX$ 的概率密度函数为

$$f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y}{a}\right)$$

因此

$$\begin{aligned} h(Y) &= - \int f_Y(y) \log f_Y(y) dy \\ &= - \int \frac{1}{|a|} f_X\left(\frac{y}{a}\right) \log \left(\frac{1}{|a|} f_X\left(\frac{y}{a}\right) \right) dy \\ &= - \int f_X(x) \log \left(\frac{1}{|a|} f_X(x) \right) dx \quad (y = ax) \\ &= h(X) + \log |a| \end{aligned}$$

□

Theorem 6.4.8.

$$h(AX) = h(X) + \log |\det A|, \forall A \in GL_n(\mathbb{R})$$

证明类似。

在具有相同协方差矩阵的随机向量中，多元正态分布具有最大的微分熵:

Theorem 6.4.9. 设 X 为均值为 μ ，协方差矩阵为 $K = \mathbb{E}[(X - \mu)(X - \mu)^T]$ 的随机向量，则

$$h(X) \leq \frac{1}{2} \log((2\pi e)^n |K|)$$

取等 $\iff X \sim N(\mu, K)$

Proof. 不妨设 $\mu = 0$ 。设 g 为任意满足 $\mathbb{E}[gg^T] = K$ 的多元正态分布的概率密度函数， $\phi_K \sim \mathcal{N}(0, K)$ ，则概率密度函数为

$$\phi_K(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |K|^{1/2}} \exp\left(-\frac{1}{2} \mathbf{x}^T K^{-1} \mathbf{x}\right)$$

于是

$$\begin{aligned} 0 \leq D(g||\phi_K) &= \int g(\mathbf{x}) \log \frac{g(\mathbf{x})}{\phi_K(\mathbf{x})} d\mathbf{x} \\ &= \int g(\mathbf{x}) \log g(\mathbf{x}) d\mathbf{x} - \int g(\mathbf{x}) \log \phi_K(\mathbf{x}) d\mathbf{x} \\ &= -h(g) + \frac{1}{2} \int g(\mathbf{x}) \mathbf{x}^T K^{-1} \mathbf{x} d\mathbf{x} + \frac{1}{2} \log((2\pi)^n |K|) \\ &= -h(g) + \frac{1}{2} \text{tr}(K^{-1} K) + \frac{1}{2} \log((2\pi)^n |K|) \\ &= -h(g) + \frac{1}{2} \log((2\pi e)^n |K|) \end{aligned}$$

利用了例6.1.1的结论。 □

特别地，具有相同方差的随机变量中，正态分布具有最大的微分熵。

由此可得与Fano不等式类似的估计：

Theorem 6.4.10. 设 X 微分熵为 $h(X)(\text{nat})$ ，常量 $\hat{X}$ 为 X 的估计，则

$$\mathbb{E}(X - \hat{X})^2 \geq \frac{1}{2\pi e} e^{2h(X)}$$

取等 $\iff X$ 为正态分布且 $\hat{X} = \mathbb{E}[X]$

Proof.

$$\begin{aligned} \mathbb{E}(X - \hat{X})^2 &\geq \mathbb{E}(X - \mathbb{E}[X])^2 \\ &= \text{Var}(X) \\ &\geq \frac{1}{2\pi e} e^{2h(X)} \end{aligned}$$

最后一行是因为在具有相同方差的随机变量中，正态分布具有最大的微分熵，因此

$$h(X) \leq \frac{1}{2} \log(2\pi e \text{Var}(X))$$

□

Corollary 6.4.11. 当边信息 Y 以及估计 $\hat{X}(Y)$ 已知时, 有

$$\mathbb{E}(X - \hat{X}(Y))^2 \geq \frac{1}{2\pi e} e^{2h(X|Y)}$$

第七章 最后一页