

# 信息论

Leo Yan

2026 年 3 月 4 日

# 目录

|                         |           |
|-------------------------|-----------|
| <b>第一章 熵, 相对熵, 互信息</b>  | <b>3</b>  |
| 1.1 基本概念 . . . . .      | 3         |
| 1.2 多维随机变量 . . . . .    | 4         |
| 1.3 不等式 . . . . .       | 6         |
| 1.4 其他背景下的不等式 . . . . . | 7         |
| <b>第二章 渐进均分性</b>        | <b>10</b> |
| 2.1 渐进均分性 . . . . .     | 10        |
| <b>第三章 熵率与Markov链</b>   | <b>12</b> |
| 3.1 熵率 . . . . .        | 12        |
| 3.2 Markov链 . . . . .   | 12        |
| <b>第四章 数据压缩</b>         | <b>15</b> |
| 4.1 编码理论 . . . . .      | 15        |
| 4.2 Huffman编码 . . . . . | 19        |
| 4.3 其他编码 . . . . .      | 20        |
| <b>第五章 信道容量</b>         | <b>22</b> |
| 5.1 通信系统模型 . . . . .    | 22        |
| 5.2 联合典型序列 . . . . .    | 25        |
| 5.3 信道编码定理 . . . . .    | 26        |
| <b>第六章 最后一页</b>         | <b>28</b> |

# 第一章 熵，相对熵，互信息

## 1.1 基本概念

**Definition 1.1.1** (熵). 设 $X$ 是离散型随机变量，取值（样本空间）为 $\mathcal{X}$ ，概率分布为 $p(x)$ ，则 $X$ 的熵(entropy)定义为

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log p(x) = \mathbb{E}_p \left[ \log \frac{1}{p(X)} \right]$$

单位为比特（bit）；若以自然对数为底，则单位为纳特（nat）

$$H(X) \geq 0; \quad H_b(X) = \log_b a \cdot H_a(X)$$

也记为 $H(p)$

*Remark 1.1.1.* 熵描述随机变量的不确定度；给出了描述随机变量所需的信息量的下界

**Definition 1.1.2** (联合熵). 设 $(X, Y)$ 为联合分布的离散型随机变量，则 $(X, Y)$ 的联合熵(joint entropy)定义为

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(x, y) = \mathbb{E}_p \left[ \log \frac{1}{p(X, Y)} \right]$$

也记为 $H(XY)$

**Definition 1.1.3** (条件熵). 设 $(X, Y)$ 为联合分布的离散型随机变量，则在已知 $Y$ 的条件下 $X$ 的条件熵(conditional entropy)定义为

$$H(X|Y) = - \sum_{y \in \mathcal{Y}} p(y) \sum_{x \in \mathcal{X}} p(x|y) \log p(x|y) = \mathbb{E}_p \left[ \log \frac{1}{p(X|Y)} \right]$$

**Theorem 1.1.1** (链式法则). 设 $(X, Y)$ 为联合分布的离散型随机变量，则有

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

**Proof.**

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(x, y)$$

$$\begin{aligned}
&= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x)p(y|x) \log[p(x)p(y|x)] \\
&= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(x) - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(y|x) \\
&= H(X) + H(Y|X)
\end{aligned}$$

□

**Definition 1.1.4** (相对熵). 设 $p$ 和 $q$ 为定义在同一样本空间 $\mathcal{X}$ 上的两个离散概率分布, 则 $p$ 相对于 $q$ 的相对熵(relative entropy)或Kullback-Leibler散度(KL散度)定义为

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} = \mathbb{E}_p \left[ \log \frac{p(X)}{q(X)} \right]$$

*Remark 1.1.2.* 描述两个概率分布之间的差异; 真实分布为 $p$ , 假设分布为 $q$ 的无效性

**Definition 1.1.5** (互信息). 设 $(X, Y)$ 为联合分布的离散型随机变量, 则 $X$ 和 $Y$ 的互信息(mutual information)定义为

$$I(X; Y) = D(p(x, y)||p(x)p(y)) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log \frac{p(x, y)}{p(x)p(y)} = \mathbb{E}_p \left[ \log \frac{p(X, Y)}{p(X)p(Y)} \right]$$

*Remark 1.1.3.* 描述两个随机变量之间共享的信息量, 或 $X$ 包含 $Y$ 的信息量

**Proposition 1.1.2** (互信息的性质). 设 $(X, Y)$ 为联合分布的离散型随机变量, 则有

1.  $I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$
2.  $I(X; Y) = H(X) + H(Y) - H(X, Y)$
3.  $I(X; X) = H(X)$

*Remark 1.1.4.* 以上三条性质的直观:

- 给定 $X$ ,  $Y$ 的不确定性减少了 $I(X; Y)$
- 容斥原理
- 熵又是自信息(self-information)

## 1.2 多维随机变量

### 符号说明

- (1)  $H(X, Y, Z)$ 实际上应该理解为 $H((X, Y, Z))$ , 即 $H$ 总为一元函数
- (2)  $I(X; Y, Z)$ 实际上应该理解为 $I(X; (Y, Z))$ , 即 $I(\cdot; \cdot)$ 总为二元函数
- (3)  $H(X, Y|Z)$ 实际上应该理解为 $H((X, Y)|Z)$ , 即 $H(\cdot|\cdot)$ 总为二元函数; 同理 $I(X; Y|Z)$ 实际上应该理解为 $I(X; Y|Z)$ , 即 $I(\cdot; \cdot|\cdot)$ 总为三元函数。应该认为“;”的优先级高于“|”
- (4)  $D$ 虽称为熵, 但不是随机变量的函数, 而是分布的函数。”||”类似于“;”,  $D$ 总为二元函数

**Definition 1.2.1** (条件互信息).  $X, Y$ 在已知 $Z$ 的条件下的条件互信息(conditional mutual information)定义为

$$I(X; Y|Z) = \sum_{z \in \mathcal{Z}} p(z) \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y|z) \log \frac{p(x, y|z)}{p(x|z)p(y|z)} = \mathbb{E}_p \left[ \log \frac{p(X, Y|Z)}{p(X|Z)p(Y|Z)} \right]$$

*Remark 1.2.1.* 描述已知 $Z$ , 给出 $Y$ 引起的 $X$ 的不确定度减少量

**Definition 1.2.2** (条件相对熵). 对于联合概率质量函数 $p(x, y)$ 和 $q(x, y)$ ,  $X$ 在已知 $Y$ 的条件下的条件相对熵(conditional relative entropy)定义为

$$D(p(x|y)||q(x|y)) = \sum_{y \in \mathcal{Y}} p(y) \sum_{x \in \mathcal{X}} p(x|y) \log \frac{p(x|y)}{q(x|y)} = \mathbb{E}_p \left[ \log \frac{p(X|Y)}{q(X|Y)} \right]$$

**Theorem 1.2.1** (熵的链式法则).

$$H(X_1, X_2, \dots, X_n) = \sum_{i=1}^n H(X_i|X_1, X_2, \dots, X_{i-1})$$

**Proof.** 反复使用

$$H(X, Y) = H(X) + H(Y|X)$$

□

**Theorem 1.2.2** (互信息的链式法则).

$$I(X; Y_1, Y_2, \dots, Y_n) = \sum_{i=1}^n I(X; Y_i|Y_1, Y_2, \dots, Y_{i-1})$$

**Proof.**

$$I(\mathbf{X}; \mathbf{Y}) = H(\mathbf{Y}) - H(\mathbf{Y}|\mathbf{X})$$

□

**Theorem 1.2.3** (相对熵的链式法则).

$$D(p(x, y)||q(x, y)) = D(p(x)||q(x)) + D(p(y|x)||q(y|x))$$

**Proof.**

$$\begin{aligned} D(p(x, y)||q(x, y)) &= \mathbb{E}_{p(x, y)} \log \frac{p(X, Y)}{q(X, Y)} \\ &= \mathbb{E}_{p(x, y)} \log \frac{p(X)p(Y|X)}{q(X)q(Y|X)} \\ &= \mathbb{E}_{p(x)} \log \frac{p(X)}{q(X)} + \mathbb{E}_{p(x, y)} \log \frac{p(Y|X)}{q(Y|X)} \\ &= D(p(x)||q(x)) + D(p(y|x)||q(y|x)) \end{aligned}$$

□

### 1.3 不等式

**Theorem 1.3.1** (Jensen不等式). 设 $X$ 为离散型随机变量, 取值(样本空间)为 $\mathcal{X}$ , 概率分布为 $p(x)$ , 且 $f$ 为凸函数, 则有

$$\mathbb{E}_p[f(X)] \geq f(\mathbb{E}_p[X])$$

进一步, 若 $f$ 为严格凸函数, 则等号成立  $\iff X = \mathbb{E}X$

**Theorem 1.3.2** (信息不等式). 设 $p$ 和 $q$ 为定义在同一样本空间 $\mathcal{X}$ 上的两个离散概率分布, 则有

$$D(p||q) \geq 0$$

取等  $\iff p = q$

**Proof.**  $\log$ 在 $(0, +\infty)$ 上为严格凹函数, 故 $-\log$ 为严格凸。考虑

$$A = \{x \in \mathcal{X} : p(x) > 0, q(x) > 0\}$$

则由Jensen不等式,

$$\begin{aligned} D(p||q) &= \sum_{x \in A} p(x) \log \frac{p(x)}{q(x)} \\ &= - \sum_{x \in A} p(x) \left[ -\log \frac{q(x)}{p(x)} \right] \\ &\geq -\log \left( \sum_{x \in A} p(x) \frac{q(x)}{p(x)} \right) \\ &= -\log \left( \sum_{x \in A} q(x) \right) \\ &\geq 0 \end{aligned}$$

□

**Corollary 1.3.3.**

$$I(X; Y) \geq 0$$

取等  $\iff X$ 与 $Y$ 独立

条件相对熵、条件互信息也是非负的

**Corollary 1.3.4.**

$$H(X|Y) \leq H(X)$$

取等  $\iff X$ 与 $Y$ 独立

*Remark 1.3.1.* 条件导致熵减小。但 $H(X|Y = y)$ 可能大于 $H(X)$ , 不等式仅描述平均性质

**Theorem 1.3.5.**

$$H(X) \leq \log |\mathcal{X}|$$

取等  $\iff X \sim U_{\mathcal{X}}$ **Corollary 1.3.6** (熵的独立界).

$$H(X_1, X_2, \dots, X_n) \leq \sum_{i=1}^n H(X_i)$$

取等  $\iff X_1, X_2, \dots, X_n$  相互独立**Proof.** 由链式法则,

$$H(X_1, X_2, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, X_2, \dots, X_{i-1}) \leq \sum_{i=1}^n H(X_i)$$

□

## 1.4 其他背景下的不等式

**Definition 1.4.1.** 如果Z的条件分布 $p(z|x, y)$ 仅依赖于y而与x条件独立, 即

$$p(x, y, z) = p(x)p(y|x)p(z|y)$$

则称随机变量三元组 $(X, Y, Z)$ 构成马尔可夫链(Markov chain), 记为 $X \rightarrow Y \rightarrow Z$   
条件独立的意思是

$$p(x, z|y) = p(x|y)p(z|y)$$

 $X, Z$ 对称, 即 $X \rightarrow Y \rightarrow Z \iff Z \rightarrow Y \rightarrow X$ , 因此可记 $X \leftrightarrow Y \leftrightarrow Z$ **Theorem 1.4.1** (数据处理不等式). 设随机变量三元组 $(X, Y, Z)$ 构成马尔可夫链 $X \rightarrow Y \rightarrow Z$ , 则有

$$I(X; Y) \geq I(X; Z)$$

取等  $\iff X \rightarrow Z \rightarrow Y$ **Proof.** 用互信息的链式法则,

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) = I(X; Z) + I(X; Y|Z)$$

给定Y, X与Z独立, 即 $I(X; Z|Y) = 0$ , 而 $I(X; Y|Z) \geq 0$ , 故

$$I(X; Y) \geq I(X; Z)$$

□

*Remark 1.4.1.* 对Y的数据处理不能增加其包含X的信息

**Corollary 1.4.2.**

$$I(X;Y) \geq I(X, g(Y))$$

$$X \rightarrow Y \rightarrow Z \implies I(X;Y|Z) \leq I(X;Y)$$

*Remark 1.4.2.* 观察下游随机变量,  $X, Y$  的依赖程度可能降低

**Definition 1.4.2** (充分统计量). 假定有一族概率质量函数  $\{f_\theta(x)\}$ ,  $X$  是从其中一个分布  $f_\theta(x)$  中抽取的样本,  $T(X)$  是  $X$  的一个统计量, 则

$$\theta \rightarrow X \rightarrow T(X)$$

由数据处理不等式, 有

$$I(\theta; X) \geq I(\theta; T(X))$$

取等时统计量  $T(X)$  未损失  $X$  关于参数  $\theta$  的信息, 称  $T(X)$  为关于分布族  $\{f_\theta(x)\}$  的充分统计量(sufficient statistic)

等价定义: 给定  $T(X)$ ,  $X$  与  $\theta$  条件独立, 即  $\theta \rightarrow T(X) \rightarrow X$

**Definition 1.4.3** (最小充分统计量). 关于分布族  $\{f_\theta(x)\}$  的充分统计量  $T(X)$  是其他任何充分统计量  $U(X)$  的函数, 则称  $T(X)$  为关于  $\{f_\theta(x)\}$  的最小充分统计量(minimal sufficient statistic)  
定义蕴含  $\theta \rightarrow T(X) \rightarrow U(X) \rightarrow X$

*Remark 1.4.3.* 最小充分统计量最大程度地压缩了样本  $X$  中关于  $\theta$  的信息, 而其他充分统计量可能包含冗余信息

由随机变量  $Y$  估计与之有关的  $X$ ,  $X$  的估计值记为  $\hat{X} = g(Y)$  取值空间为  $\hat{\mathcal{X}}$ , 则有马尔可夫链  $X \rightarrow Y \rightarrow \hat{X}$ 。定义误差概率  $P_e = P\{\hat{X} \neq X\}$ 。

**Theorem 1.4.3** (Fano不等式). 设  $X$  为离散型随机变量, 取值(样本空间)为  $\mathcal{X}$ , 则有

$$H(P_e) + P_e \log(|\mathcal{X}| - 1) \geq H(X|\hat{X}) \geq H(X|Y)$$

可减弱为

$$1 + P_e \log |\mathcal{X}| \geq H(X|Y) \implies P_e \geq \frac{H(X|Y) - 1}{\log |\mathcal{X}|}$$

**Proof.** 设错误指示变量  $E = \mathbb{1}_{\{\hat{X} \neq X\}}$ , 则有马尔可夫链  $X \rightarrow Y \rightarrow \hat{X} \rightarrow E$ 。由链式法则,

$$\begin{aligned} H(X, E|\hat{X}) &= H(E|\hat{X}) + H(X|E, \hat{X}) \\ &= H(X|\hat{X}) + H(E|X, \hat{X}) \end{aligned}$$

因为  $H(E|X, \hat{X}) = 0$ , 所以

$$H(X|\hat{X}) = H(E|\hat{X}) + H(X|E, \hat{X})$$

注意到

$$H(E|\hat{X}) \leq H(E) = H(P_e)$$



且

$$H(X|E, \hat{X}) = P_e H(X|\hat{X}, E=1) + (1 - P_e) H(X|\hat{X}, E=0) \leq P_e \log(|\mathcal{X}| - 1)$$

故

$$H(X|\hat{X}) \leq H(P_e) + P_e \log(|\mathcal{X}| - 1)$$

另一方面，由数据处理不等式，

$$H(X|Y) \leq H(X|\hat{X})$$

□

**Corollary 1.4.4.** 令  $\hat{X} = Y$ ，则有

$$H(P_e) + P_e \log(|\mathcal{X}| - 1) \geq H(X|Y)$$

若  $\hat{X} = X$ ，结论变为

$$H(P_e) + P_e \log(|\mathcal{X}| - 1) \geq 0$$

**Proposition 1.4.5.** 设  $X, X'$  独立同分布，则

$$P\{X = X'\} \geq 2^{-H(X)}$$

**Corollary 1.4.6.** 设  $X, Y$  独立， $X \sim p(x)$ ， $Y \sim q(y)$ ，取值空间均为  $\mathcal{X}$ ，则

$$P\{X = Y\} \geq 2^{-H(p) - D(p||q)}, P\{X = Y\} \geq 2^{-H(q) - D(q||p)}$$

## 第二章 渐进均分性

### 2.1 渐进均分性

**Definition 2.1.1** (随机变量的收敛). 给定随机变量序列 $\{X_n\}$ 和随机变量 $X$ ,

①如果

$$\forall \epsilon > 0, P\{|X_n - X| \geq \epsilon\} \rightarrow 0 (n \rightarrow \infty)$$

则称 $X_n$ 依概率收敛于 $X$ , 记为 $X_n \xrightarrow{P} X$

②如果

$$P\{\lim_{n \rightarrow \infty} X_n = X\} = 1$$

则称 $X_n$ 几乎处处收敛 (或以概率1收敛) 于 $X$ , 记为 $X_n \xrightarrow{a.e.} X$

③如果

$$\mathbb{E}(X_n - X)^2 \rightarrow 0 (n \rightarrow \infty)$$

则称 $X_n$ 均方收敛于 $X$ , 记为 $X_n \xrightarrow{L_2} X$

**Theorem 2.1.1** (渐进均分性(Asymptotic Equipartition Property, AEP)). 以 $X$ 记信源随机变量, 它生成的序列 $X_1, X_2, \dots, X_n i.i.d. \sim p(x)$ , 则有

$$-\frac{1}{n} \log p(X_1, X_2, \dots, X_n) \xrightarrow{P} H(X)$$

**Proof.**

$$X_k i.i.d. \sim p(x) \implies -\log p(X_k) i.i.d. \sim -\log p(x)$$

由弱大数定律,

$$\frac{1}{n} \sum_{k=1}^n -\log p(X_k) \xrightarrow{P} \mathbb{E}[-\log p(X)] = H(X)$$

□

**Definition 2.1.2** (典型集). 关于 $p(x)$ 的典型集(typical set)定义为

$$A_\epsilon^{(n)} = \left\{ (x_1, x_2, \dots, x_n) \left| -\frac{1}{n} \log p(x_1, x_2, \dots, x_n) - H(X) < \epsilon \right. \right\}$$

性质:

①

$$\forall \mathbf{x} \in A_\epsilon^{(n)}, H(X) - \epsilon < -\frac{1}{n} \log p(\mathbf{x}) < H(X) + \epsilon$$

- ②  $n$ 充分大时,  $P\{A_\epsilon^{(n)}\} > 1 - \epsilon$
- ③  $|A_\epsilon^{(n)}| \leq 2^{n(H(X)+\epsilon)}$  (概率和不超过1)
- ④ (第一条的推论)  $n$ 充分大时,  $|A_\epsilon^{(n)}| \geq (1 - \epsilon)2^{n(H(X)-\epsilon)}$

*Remark 2.1.1.* 直观:

- ①  $\implies$  典型集中的元素在数量级意义下是几乎等可能的;
- ②  $\implies$  典型集出现概率随 $n$ 增大而趋近于1 (渐进);
- ③④  $\implies$  典型集的元素个数近似等于 $2^{nH(X)}$  (均分)

设 $X_n$  i.i.d.  $\sim p(x)$ , 存在一个编码将长为 $n$ 的序列映射为比特串, 且映射为双射 (从而可逆), 其码字长度 $l(x_n)$ 满足

$$\lim_{n \rightarrow \infty} \mathbb{E} \left[ \frac{1}{n} l(x_n) \right] = H(X)$$

因而理论上用 $nH(X)$ 比特即可表示序列 $x_1, x_2, \dots, x_n$  (等长码需要 $n \log |\mathcal{X}|$ 比特)

码字长度: 信源编码时某个符号 $x$ 使用的比特数为 $l(x)$ ;  $x^n$ 使用的比特数为 $l(x^n)$

**Proof.** 考虑给大概率的典型集较短的编码。

$$A_\epsilon^{(n)} \leq 2^{n(H(X)+\epsilon)} \implies [n(H(X) + \epsilon)] \leq n(H(X) + \epsilon) + 1(\text{bit})$$

可表示 $A_\epsilon^{(n)}$ 中的每个序列, 同理 $n \log |\mathcal{X}| + 1$ bit可表示 $A_\epsilon^{(n)c}$

在典型集序列前标0而在非典型集序列前标1作为表示为, 则码字长度

$$l(x^n) \leq \begin{cases} n(H(X) + \epsilon) + 2, & x^n \in A_\epsilon^{(n)} \\ n \log |\mathcal{X}| + 2, & x^n \in A_\epsilon^{(n)c} \end{cases}$$

取 $n$ 充分大使 $P\{A_\epsilon^{(n)}\} > 1 - \epsilon$ , 则

$$\begin{aligned} \mathbb{E}[l(x^n)] &= \sum_{x^n \in \mathcal{X}^n} p(x^n) l(x^n) \\ &\leq P\{A_\epsilon^{(n)}\} [n(H(X) + \epsilon) + 2] + P\{A_\epsilon^{(n)c}\} [n \log |\mathcal{X}| + 2] \\ &\leq (1 - \epsilon) [n(H(X) + \epsilon) + 2] + \epsilon [n \log |\mathcal{X}| + 2] = n(H(X) + \epsilon') \end{aligned}$$

其中 $\epsilon' = \epsilon \log |\mathcal{X}| - \epsilon H(X) + 2/n$

$$\begin{aligned} \mathbb{E}[l(x^n)] &\geq P\{A_\epsilon^{(n)}\} [n(H(X) + \epsilon) + 1] + P\{A_\epsilon^{(n)c}\} [n \log |\mathcal{X}| + 1] \\ &\geq (1 - \epsilon) [n(H(X) + \epsilon) + 1] + \epsilon [n \log |\mathcal{X}| + 1] = n[(1 - \epsilon)H(X) + \epsilon''] \end{aligned}$$

其中 $\epsilon'' = \epsilon(1 - \epsilon) + \frac{1-\epsilon}{n}$

□

*Remark 2.1.2.* 熵是无损压缩的下限

## 第三章 熵率与Markov链

### 3.1 熵率

**Definition 3.1.1** (熵率). 设 $\{X_n\}$ 为随机过程, 则 $\{X_n\}$ 的熵率(entropy rate)在极限存在时定义为

$$H(\mathcal{X}) = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, X_2, \dots, X_n)$$

**Theorem 3.1.1.** 定义

$$H'(\mathcal{X}) = \lim_{n \rightarrow \infty} H(X_n | X_1, X_2, \dots, X_{n-1})$$

对于平稳过程, 两种极限均存在且 $H(\mathcal{X}) = H'(\mathcal{X})$

**Proof.**

$$H(X_{n+1} | X_1, X_2, \dots, X_n) \leq H(X_{n+1} | X_2, X_3, \dots, X_{n+1}) = H(X_n | X_1, X_2, \dots, X_{n-1})$$

因此 $H(X_n | X_1, X_2, \dots, X_{n-1})$ 非负递减,  $H'(\mathcal{X})$ 存在。

由链式法则,

$$\frac{1}{n} H(X_1, X_2, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n H(X_i | X_1, X_2, \dots, X_{i-1})$$

即熵率为条件熵的时间平均值。 $H_n(\mathcal{X})$ 为 $H'(\mathcal{X})$ 的Cesàro和, 故 $H(\mathcal{X}) = H'(\mathcal{X})$  □

### 3.2 Markov链

**Theorem 3.2.1.** 对于平稳的Markov链 $\{X_n\}$ , 设平稳分布为 $\mu$ , 转移概率矩阵为 $P$ , 则熵率为

$$H(\mathcal{X}) = H(X_2 | X_1) = \sum_i \mu_i \sum_j P_{ij} \log \frac{1}{P_{ij}}$$

**Proof.**

$$\begin{aligned} H'(\mathcal{X}) &= \lim_{n \rightarrow \infty} H(X_n | X_1, X_2, \dots, X_{n-1}) \\ &= \lim_{n \rightarrow \infty} H(X_n | X_{n-1}) \\ &= H(X_2 | X_1) \end{aligned}$$

$$= \sum_i \mu_i \sum_j P_{ij} \log \frac{1}{P_{ij}}$$

□

**Theorem 3.2.2.** 设 $\mu_n, \mu'_n$ 为 $n$ 时刻同一Markov链的两条轨迹的分布, 则

$$D(\mu_n || \mu'_n) \geq D(\mu_{n+1} || \mu'_{n+1})$$

特别地,

$$D(\mu_n || \mu) \geq D(\mu_{n+1} || \mu)$$

**Proof.** 记 $\mu_n, \mu'_n$ 对应两盒概率分布为 $p, q$ ,  $r(\cdot|\cdot)$ 为转移概率分布, 则

$$p(x_n, x_{n+1}) = p(x_n)r(x_{n+1}|x_n), q(x_n, x_{n+1}) = q(x_n)r(x_{n+1}|x_n)$$

由相对熵的链式法则,

$$\begin{aligned} D(p(x_n)||q(x_n)) \\ &= D(p(x_n)||q(x_n)) + D(r(x_{n+1}|x_n)||r(x_{n+1}|x_n)) \\ &= D(p(x_{n+1})||q(x_{n+1})) + D(p(x_n|x_{n+1})||q(x_n|x_{n+1})) \end{aligned}$$

由于 $D(r||r) = 0, D(p||q) \geq 0$ , 因此 $D(p(x_n)||q(x_n)) \geq D(p(x_{n+1})||q(x_{n+1}))$ , 即 $D(\mu_n || \mu'_n) \geq D(\mu_{n+1} || \mu'_{n+1})$ 。 □

*Remark 3.2.1.* 相同转移概率下, 不同初始分布趋同于平稳分布

**Corollary 3.2.3.** 若平稳分布 $\mu$ 为均匀分布, 则熵增大, 即 $H(\mu_n) \leq H(\mu_{n+1})$

**Proof.**

$$\begin{aligned} D(\mu_n || \mu) &= \sum_{x_n} \mu_n(x_n) \log \frac{\mu_n(x_n)}{1/|\mathcal{X}|} \\ &= \log |\mathcal{X}| - H(\mu_n) \\ &= \log |\mathcal{X}| - H(X_n) \end{aligned}$$

□

*Remark 3.2.2.* 热学中的熵 $S = \log \Omega$ 在各状态等可能的前提下与信息熵一致, 这解释了热二律“熵增大”

**Definition 3.2.1.** 转移概率矩阵 $P$ 的行和为1:  $\sum_j P_{ij} = 1$ , 且 $P_{ij} \geq 0$ 。若 $P$ 列和也为1:  $\sum_i P_{ij} = 1$ , 则 $P$ 是双随机矩阵(doubly stochastic matrix)  
均匀分布是平稳分布  $\iff P$ 双随机

**Theorem 3.2.4.** 对于平稳的Markov链 $\{X_n\}$ ,  $H(X_{n+1}|X_1) \geq H(X_n|X_1)$

**Proof.**

$$H(X_{n+1}|X_1) \geq H(X_{n+1})|X_1, X_2 = H(X_{n+1})|X_2 = H(X_n|X_1)$$

□

**Lemma 3.2.5.** 设 $\{X_n\}$ 为平稳的Markov链,  $\{Y_n\}$ 为 $\{X_n\}$ 的对应项的函数, 熵率为 $H(\mathcal{Y})$ , 则

$$H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \leq H(\mathcal{Y})$$

**Proof.**

$$\begin{aligned} H(Y_n|Y_{n-1}, \dots, Y_1, X_1) &\leq H(Y_n|Y_{n-1}, \dots, Y_1, X_1, X_0, \dots, X_{-k}) && (\text{Markov性}) \\ &= H(Y_n|Y_{n-1}, \dots, Y_1, \dots, Y_{-k}, X_1, X_0, \dots, X_{-k}) && (Y_k = \phi_k(X_k)) \\ &\leq H(Y_n|Y_{n-1}, \dots, Y_1, \dots, Y_{-k}) \\ &= H(Y_{n+k+1}|Y_{n+k}, \dots, Y_1) && (\text{平稳性}) \end{aligned}$$

令 $k \rightarrow \infty$ , 则

$$H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \leq \lim_{k \rightarrow \infty} H(Y_{n+k+1}|Y_{n+k}, \dots, Y_1) = H(\mathcal{Y})$$

□

**Lemma 3.2.6.**

$$H(Y_n|Y_{n-1}, \dots, Y_1) - H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \rightarrow 0, n \rightarrow \infty$$

**Proof.**

$$\begin{aligned} H(X_1) &\geq \lim_{n \rightarrow \infty} I(X_1; Y_n|Y_{n-1}, \dots, Y_1) \\ &= \sum_{n=1}^{\infty} I(X_1; Y_n|Y_{n-1}, \dots, Y_1) && (\text{链式法则}) \\ &= \sum_{n=1}^{\infty} [H(Y_n|Y_{n-1}, \dots, Y_1) - H(Y_n|Y_{n-1}, \dots, Y_1, X_1)] \end{aligned}$$

□

又由3.1.1,

$$\{X_n\} \text{平稳} \implies H(X_n|X_1, X_2, \dots, X_{n-1}) \downarrow H(\mathcal{X})$$

**Theorem 3.2.7.** 设 $\{X_n\}$ 为平稳的Markov链,  $\{Y_n\}$ 为 $\{X_n\}$ 的对应项的函数, 熵率为 $H(\mathcal{Y})$ , 则

$$H(Y_n|Y_{n-1}, \dots, Y_1, X_1) \leq H(\mathcal{Y}) \leq H(Y_n|Y_{n-1}, \dots, Y_1)$$

且

$$\lim_{n \rightarrow \infty} H(Y_n|Y_{n-1}, \dots, Y_1, X_1) = H(\mathcal{Y}) = \lim_{n \rightarrow \infty} H(Y_n|Y_{n-1}, \dots, Y_1)$$

## 第四章 数据压缩

### 4.1 编码理论

**Definition 4.1.1.** 字母表 设 $X$ 是取值空间为 $\mathcal{X}$ 的随机变量,  $\Sigma$ 为 $D$ 元字母表(alphabet),  $\Sigma^*$ 表示 $\Sigma$ 上有限长字符串构成的集合。  
总假设 $D$ 元字母表为 $\{0, 1, \dots, D-1\}$ 。

**Definition 4.1.2** (信源编码). 信源编码(source code)为映射 $C: \mathcal{X} \rightarrow \Sigma^*$ 。  
 $x$ 的码字(codeword)记为 $C(x)$ , 其长度记为 $l(x)$   
若 $C$ 是单射, 称该编码是非奇异的(nonsingular)。

**Definition 4.1.3** (期望长度). 设 $X \sim p(x)$ , 信源编码 $C$ 的期望长度(expected length)为

$$L(C) = \mathbb{E}_p l(X) = \sum_{x \in \mathcal{X}} p(x) l(x)$$

**Definition 4.1.4** (前缀码).  $C$ 是前缀码(prefix code)或即时码(instantaneous code), 如果在序列中任一字符 $x_i$ 的码字结束时, 可以不依赖于后续码字而立即确定 $x_i$ 。  
等价定义: 没有任何码字是其他码字的前缀, 即

$$\forall c_1, c_2 \in C, c_1 \neq c_2, \nexists s \in \Sigma^*, c_1 \cdot s = c_2$$

**Theorem 4.1.1** (Kraft不等式).  $D$ 元字母表上的即时码, 码字长度 $l_1, \dots, l_m$ 满足

$$\sum_{i=1}^m D^{-l_i} \leq 1$$

给定一组满足上述不等式的码字长度, 必存在相应的即时码。

**Proof.** 考虑 $D$ 叉树, 第 $k$ 层为长为 $k$ 的字符串, 树枝表述字符。

前缀条件表明, 没有码字是其他码字的祖先, 即码字必然对应叶子。

令 $l_{\max} = \max\{l_i\}$ , 考虑 $l_{\max}$ 层中码字节点及其后代数 $M$ :

一方面,  $M \leq D^{l_{\max}}$ ;

另一方面, 位于 $l_i$ 层的码字在 $l_{\max}$ 层恰有 $D^{l_{\max}-l_i}$ 个后代, 且这些后代互相补充和, 因此

$$M = \sum_i D^{l_{\max}-l_i}$$

综上,  $\sum_{i=1}^m D^{-l_i} \leq 1$ .

反之, 依字典序将第一个深度为 $l_1$ 的节点标为码字1并去除其后代。依次对 $l_i$ 重复以上步骤。不等式保证直至最后一步, 必然存在所需层的节点。  $\square$

**Theorem 4.1.2** (推广的Kraft不等式). 任意可数的即时码字集, 码字长度 $\{l_i\}_{i=1}^{\infty}$ 满足

$$\sum_{i=1}^{\infty} D^{-l_i} \leq 1$$

反之也有相应即时码。

**Proof.** 以D进制小数

$$0.y_1y_2\cdots y_{l_i} = \sum_{j=1}^{l_i} y_j D^{-j}$$

表示码字, 则在区间

$$[0.y_1\cdots y_{l_i}, 0.y_1\cdots y_{l_i} + D^{-l_i})$$

没有其他码字。区间长度之和 $\leq 1$ 即Kraft不等式。反之构造同上。  $\square$

**Definition 4.1.5** (D进制概率分布). 如果概率质量函数 $p$ 的每个概率值形如 $D^{-n}$ ,  $n \in \mathbb{N}$ , 则称 $p$ 是D进制的(D-adic)

使用D元字母表, 信源编码的期望长度不小于以D为底的信源分布的熵:

**Theorem 4.1.3** (期望长度的估计). 设信源分布为 $p(x_i) = p_i$ , 对随机变量 $X$ 的任一D元即时码 $C$ , 令 $d = \sum D^{-l_i} \leq 1$ , D进制分布 $q_i = D^{-l_i}/d$ , 则

(1)

$$L(C) = H_D(X) + D(p||q) - \log_D c \geq H_D(X)$$

取等时必须满足: 分配最优码长 $l_i^* = -\log_D p_i \in \mathbb{N}^*$ .

(2) $-\log_D p_i \in \mathbb{N}^*$ 的必要条件是 $p$ 是D进制分布, 此时 $p=q$ .

**Proof.**

$$\begin{aligned} L(C) - H_D(X) &= \sum p_i l_i - \sum p_i \log_D \frac{1}{p_i} \\ &= \sum p_i \log_D p_i D^{-l_i} \\ &= \sum p_i \log_D \frac{p_i}{q_i} \cdot \frac{1}{c} \\ &= \sum p_i \log_D \frac{p_i}{q_i} - \log_D c \\ &= D(p||q) - \log_D c \geq 0 \end{aligned} \quad (\text{相对熵非负})$$

下面说明 $q_i$ 及最优码长的由来, 即最优化问题:

在 $l_i \in \mathbb{N}, \sum D^{-l_i} \leq 1$ 的条件下, 求 $\min L(C)$ .

不考虑 $l_i \in \mathbb{N}, \Omega = \{\mathbf{x} \in \mathbb{R}^m : \sum D^{-l_i} \leq 1\}$ 是凸集, 因为 $\forall \mathbf{x}, \mathbf{y} \in \Omega$ , 由Hölder不等式,

$$\sum_i D^{-\lambda x_i - (1-\lambda)y_i} \leq \left( \sum_i D^{-x_i} \right)^\lambda \left( \sum_i D^{-y_i} \right)^{1-\lambda} \leq 1, \forall 0 < \lambda < 1$$



用拉乘法求 $\min_{\mathbf{x} \in \Omega} L(C)$ . 令

$$J(l_1, \dots, l_m, \lambda) = \sum_i p_i l_i + \lambda \left( \sum_i D^{-l_i} - 1 \right)$$

再令

$$\frac{\partial J}{\partial l_i} = p_i - \lambda D^{-l_i} \log D = 0$$

得

$$D^{-l_i} = \frac{p_i}{\lambda \log D}$$

代回条件 $\mathbf{x} \in \partial\Omega$ 得 $\lambda = 1/\log D$ , 从而最优码长为

$$l_i^* = -\log_D p_i$$

□

以上过程提供了寻找最优编码（在 $D(p||q)$ 最小的意义下）的流程：寻找最接近 $X \sim p$ 的D进制分布q, 按q选取码字长度, 再用Kraft不等式证明中的方法构造编码。按此流程构造的编码是香农码：

**Definition 4.1.6** (香农码). 满足 $l_i = -\log_D p_i$ 的编码称为香农码。

以下定理从期望长度的角度阐释了香农码的有效性：

**Theorem 4.1.4.** 设 $\{l_i^*\}_{i=1}^m$ 是关于信源分布 $p$ 和 $D$ 元字母表的最优码长,  $L^* = \sum p_i l_i^*$ 为期望长度, 则

$$H_D(X) \leq L^* < H_D(X) + 1$$

**Proof.** 令

$$l_i = \left\lceil \log_D \frac{1}{p_i} \right\rceil \in \left[ \log_D \frac{1}{p_i}, \log \frac{1}{p_i} + 1 \right)$$

它满足Kraft不等式：

$$\sum D^{l_i} \leq \sum D^{-\log \frac{1}{p_i}} = 1$$

这样就构造出在所需区间中的期望长度。

□

下面总令 $D=2$ 。

通过对字符进行分组编码, 可以减少每字符的附加位, 从而降低L:

**Theorem 4.1.5.** 考虑将 $\mathbf{x} = (x_1, \dots, x_n)$ 视为 $\mathcal{X}^n$ 中的超字符,  $l(\mathbf{x})$ 为 $\mathbf{x}$ 的码字长度, 则每输入字符的最小期望码字长度满足

$$\frac{1}{n} H(\mathbf{X}) \leq L_n^* < \frac{1}{n} H(\mathbf{X}) + \frac{1}{n}$$

进一步, 若 $\{X_j\}$ 是平稳过程, 则

$$\lim_{n \rightarrow \infty} L_n^* = H(\mathcal{X})$$

**Proof.**

$$L_n = \frac{1}{n} \sum p(\mathbf{x}) l(\mathbf{x}) = \frac{1}{n} \mathbb{E} l(\mathbf{X})$$

按

$$l(\mathbf{x}_i) = \left\lceil \log \frac{1}{p(\mathbf{x}_i)} \right\rceil$$

分配码长，则构造出所需区间中的 $L_n$ 。后一命题得自夹逼定理。  $\square$

以下定理估计了考虑偏码(wrong code)时的期望码长:

**Theorem 4.1.6.** 如果非真实分布 $q$ 是对真实分布 $p$ 的最佳估计，则在码长分配

$$l(x) = \left\lceil \log \frac{1}{q(x)} \right\rceil$$

下，关于 $p(x)$ 的期望长度满足：

$$H(p) + D(p||q) \leq \mathbb{E}_p l(X) < H(p) + D(p||q) + 1$$

**Proof.**

$$l(x) \in \left[ \log \frac{1}{q(x)}, \log \frac{1}{q(x)} + 1 \right)$$

类似thm4.1.4.带入即证。  $\square$

以下定理表明，仅仅要求编码唯一可译，而不要求即时性，也无法找到更小码长：

**Theorem 4.1.7** (McMillan定理). 任一唯一可译的 $D$ 元码也满足Kraft不等式 $\sum D^{l_i} \leq 1$ ；反之，给定一组码字长度 $\{l_i\}$ 满足 $\sum D^{l_i} \leq 1$ ，必有对应的唯一可译码。

**Proof.**  $\forall k \in \mathbb{N}^*$ ，考虑 $C$ 的 $k$ 次扩展，有

$$l(x_1, \dots, x_k) = \sum_{i=1}^k l(x_i)$$

注意到恒等式

$$\left( \sum_{x \in \mathcal{X}} D^{-l(x)} \right)^k = \sum_{x^k \in \mathcal{X}^k} D^{-l(x_1)} \dots D^{-l(x_k)} = \sum_{x^k \in \mathcal{X}^k} D^{-l(\mathbf{x})}$$

按码字长度合并同类项：

$$\sum_{x^k \in \mathcal{X}^k} D^{-l(\mathbf{x})} = \sum_{m=1}^{kl_{\max}} a_m D^{-m}$$

唯一可译性要求 $a_m \leq D^m$ ，于是

$$\sum_{m=1}^{kl_{\max}} a_m D^{-m} \leq kl_{\max}$$

即

$$\sum D^{-l_j} \leq (kl_{\max})^{1/k}$$

令 $k \rightarrow \infty$ 即得。  $\square$

**Corollary 4.1.8.** 无限信源字母表 $\mathcal{X}$ 的唯一可译码满足Kraft不等式。

**Proof.** 唯一可译码的有限子集仍是唯一可译的。  $\square$

## 4.2 Huffman编码

Huffman编码是最优编码的构造算法。给定D元字母表 $\Sigma$ , X有概率分布 $(p_1, \dots, p_n)$ , 重复执行以下步骤:

- ①将概率按降序排列
- ②在这个排列方式中, 选取末尾D个字符, 依次赋码字 $0 \sim D-1$
- ③赫夫曼合并(Huffman reduction): 将此D个字符视作一个新字符, 概率为各字符概率之和重复到只剩一个字符为止。

| Codeword Length | Codeword | X | Probability |
|-----------------|----------|---|-------------|
| 2               | 01       | 1 | 0.25        |
| 2               | 10       | 2 | 0.25        |
| 2               | 11       | 3 | 0.2         |
| 3               | 000      | 4 | 0.15        |
| 3               | 001      | 5 | 0.15        |

图 4.1: 赫夫曼编码算法执行例

*Remark 4.2.1.* ①若 $D \geq 3$ , 每一步减少字符数为D-1, 字符总数必为 $1+k(D-1)$ .如果 $|\mathcal{X}|$ 不满足条件, 需要添加概率为0的虚拟字符

②将 $p_j$ 视为权重时可以不要要求 $\sum p_j = 1$ , 此时同样可以用赫夫曼码最小化码长加权和 $\sum p_j l_j$

③赫夫曼码不唯一。例如


$$D = 2, p = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$$

| Codeword | X     | Probability |
|----------|-------|-------------|
| 1        | 1     | 0.25        |
| 2        | 2     | 0.25        |
| 01       | 3     | 0.2         |
| 02       | 4     | 0.1         |
| 000      | 5     | 0.1         |
| 001      | 6     | 0.1         |
| 002      | Dummy | 0.0         |

图 4.2: D=3,虚拟字符使用例

上图中缩减无兄弟的节点后即得**编码树**(字符对应叶子节点)

**Example 4.2.1.** 图4.1.的编码树为



赫夫曼码是一种最优即时码。最优即时码是在期望长度最小意义下的即时码，它不是唯一的。

**Lemma 4.2.1** (最优即时码的刻画). 任给分布 $\mathbf{p}$ ,  $D=2$ , 最优即时码必然满足:

- (1)  $p_i > p_j \implies l_i \leq l_j$ , 即码长与概率反序;
  - (2) 最长的两个码字拥有相同的长度, 且对应两个最小可能字符。
- 此外, 总能构造编码满足下述条件:
- (3) 最长的两个码字仅在最后一位有差别
- 称满足(3)的最优编码是典则的(*canonical*).

**Proof.** (1)对 $p_i > p_j$ , 设编码 $C$ 满足 $l_i \leq l_j$ ,  $C'$ 为 $C$ 交换 $i, j$ 编码所得, 则有

$$\begin{aligned} L(C') - L(C) &= p_j l_i + p_i l_j - p_i l_i - p_j l_j \\ &= (p_j - p_i)(l_i - l_j) \geq 0 \end{aligned}$$

(2)(3)两个最长码字在编码树中对应兄弟节点, 否则必然可以修剪编码树(删除码字最后一位)。□

**Remark 4.2.2.** (1)赫夫曼码满足

$$H(X) \leq L(C) < H(X) + 1$$

(2)赫夫曼码是贪心算法, 即局部最优 $\rightarrow$ 全局最优

## 4.3 其他编码

### 1. 香农码

前面已经介绍。对于单个字符, 赫夫曼码与香农码都可能有更短的码字长度, 但平均意义下赫夫曼码才是最优编码。

香农码具有唯一竞争最优性: 在单局游戏中, 以甲、乙对同一随机序列的编码长短决定胜负, 则香农码是一个很好的策略。

以下设 $D=2$ .

**Theorem 4.3.1.** (1) 设  $C$  为香农码,  $C'$  为其他唯一可译码, 则

$$P\{l(X) \geq l'(X) + c\} \leq \frac{1}{2^{c-1}}$$

(2) (香农码的唯一竞争最优性) 设  $p(x)$  是二进制的,  $l(x) = \log \frac{1}{p(x)}$  为香农码的码字长度, 则

$$\forall C', P\{l(X) < l'(X)\} \geq P\{l(X) > l'(X)\}$$

取等  $\iff \forall x, l(x) = l'(x)$ 。

**Corollary 4.3.2.** 对于非二进制的  $p(x)$ , 有

$$\mathbb{E} \text{sgn}(l(X) - l'(X) - 1) \leq 0$$

其中  $l$  为香农码  $C$  的码字长度。

## 2. 费纳(Fano)编码

将概率值递减排列, 然后选取  $k$  使得

$$\left| \sum_{i=1}^k p_i - \sum_{i=k+1}^m p_i \right|$$

最小 (二分概率), 概率高者赋0, 概率低者赋1, 再对子字符集重复此过程, 直到每一字符分得唯一码字。

一般来说, 这种编码不是最优编码, 但是可以达到  $L(C) \leq H(X) + 2$ 。

## 3. Shannon-Fano-Elias 编码

考虑累积分布函数  $F(x) = \sum_{a \leq x} p(a)$  及其修正  $\bar{F}(x)$ ,  $\bar{F}(x)$  在间断点处取左右平均值。

以  $\bar{F}(x)$  的二进制表示的小数部分作为字符  $x$  的码字。在码字无限时, 取前  $\left\lceil \log \frac{1}{p(x)} \right\rceil + 1$  位即可。

编码的唯一性: 以  $\lfloor \bar{F}(x) \rfloor_{l(x)}$  记  $\bar{F}(x)$  保留  $l(x)$  位。取  $l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil + 1$ , 则

$$F(x) - \lfloor \bar{F}(x) \rfloor_{l(x)} < \frac{1}{2^{l(x)}} < \frac{1}{2} 2^{\log p(x)} = \frac{p(x)}{2}$$

即  $\lfloor \bar{F}(x) \rfloor_{l(x)}$  在  $F(x)$  下方跳变幅度以内, 对应了唯一的区间。

这种编码的特点是: 应用广泛;  $L(C) < H(X) + 2$ ; 必为前缀码 (考虑区间树可证)

# 第五章 信道容量

## 5.1 通信系统模型

**Definition 5.1.1** (信源模型). (1)根据信源输出信号所对应的随机过程是否平稳, 分为稳恒(平稳)信源和非稳恒(非平稳)信源  
(2)根据特殊的随机过程类型, 分为高斯信源、Markov信源等  
(3)信源字母表离散, 信号取值时刻离散的稳恒信源称为离散稳恒信源

**Definition 5.1.2** (信道模型). (1)按输入输出信号在幅值和时间上的取值分为离散信道(数字信道)、连续信道等  
离散信道(discrete channel)是至多可数的输入字母表 $\mathcal{X}$ 和输出字母表 $\mathcal{Y}$ , 及 $\mathcal{X}$ 到 $\mathcal{Y}$ 的转移概率模型构成的系统  
(2)如果信道输出值域信道在该时刻的输入有关, 二与先前的输入输出等无关, 则信道是无记忆信道(memoryless channel); 否则为有记忆信道  
(3)按输入输出信号之间的关系是否确定, 分为有噪信道和无噪信道等

**Definition 5.1.3** (离散无记忆信道). 离散无记忆信道(DMC)的转移概率模型可以用转移概率分布 $p(y|x)$ 描述。  
设输入字母表为 $\mathcal{X}$ , 输出字母表为 $\mathcal{Y}$ , 该DMC可以用

$$(\mathcal{X}, p(x|y), \mathcal{Y})$$

表示

离散无记忆信道的n次扩展可以用

$$(\mathcal{X}^n, p(x^n|y^n), \mathcal{Y}^n)$$

表示, 其中

$$p(y_k|x^k, y^{k-1}) = p(y_k|x_k), \forall k \in \{1, 2, \dots, n\}$$

进一步, 如果信道不带反馈(如不明确指出, 则默认不带反馈), 即输入字符不依赖于过去的输出字符, 即

$$p(x_k|x^{k-1}, y^{k-1}) = p(x_k|x^{k-1}), \forall k$$

则n次扩展的信道转移函数简化为

$$p(y^k|x^k) = \prod_{i=1}^k p(y_i|x_i), \forall k$$

**Definition 5.1.4** (信息信道容量). 离散无记忆信道的信息信道容量(information channel capacity)定义为

$$C = \max_{p(x)} I(X; Y)$$

香农第二定理将指出信息信道容量=信道容量=信道最高码率=任意小误差传输比特数/信道使用次数。

$I(X; Y)$ 关于输入分布 $p(x)$ 是紧集上的连续的凹函数, 因此最大值存在且唯一, 使用max是合理的。

**Proposition 5.1.1** (信息信道容量的性质).

- $C \geq 0$ , 取等  $\iff$  信道输出与输入独立
- $C \leq \log |\mathcal{X}|$ , 取等  $\iff X, Y$  独立且  $X \sim U_{\mathcal{X}}$
- $C \leq \log |\mathcal{Y}|$ , 取等  $\iff$  存在输入分布使得输出分布为均匀分布

**Definition 5.1.5** (对称信道). 如果离散无记忆信道的概率转移矩阵 $p(x|y)$ 是数独矩阵, 则称该信道为对称信道(symmetric channel)。数独矩阵必然是双随机。

数独矩阵可以描述为: 任何两行互为置换、任何两列也互为置换。

如果每一行 $p(\cdot|x)$ 都是同一分布的置换, 且所有列的元素和 $\sum_x p(y|x)$ 相同, 则该信道是弱对称信道(weakly symmetric channel)

**Theorem 5.1.2.** 对于弱对称信道, 信息信道容量为

$$C = \log |\mathcal{Y}| - H(p(\cdot|x))$$

其中 $p(\cdot|x)$ 为任一行的分布。取等  $\iff$  输入分布为均匀分布

**Example 5.1.1** (有噪打字机信道). 该种信道的概率转移矩阵矩阵的基本特征是, 对角线元素(不出错的概率)接近于1, 除了对角线, 每一行都有个别元素数值较大, 而其他元素极小或为0。描述了考虑失误的打字机。

输入、输出字母表相同, 输入以0.5的概率被输出端无改变地接收, 以0.5的概率变为下一个字母。字母表大小为26时,  $C = 13\text{bit}/\text{传输}$ :

一方面, 每次传输可以无误差地传输其中13个字符(仅传输奇数位置或偶数位置的字符); 另一方面,

$$C = \max I(X; Y) = \max [H(Y) - H(Y|X)] = \max H(Y) - 1 = \log 26 - 1 = \log 13\text{bit}/\text{传输}$$

取等  $\iff p(x) \sim U$




图 5.1: 离散通信信道模型

**Definition 5.1.6** ( $(M, n)$ 码). 信道 $(\mathcal{X}, p(y|x), \mathcal{Y})$ 的 $(M, n)$ 码由以下部分构成:

- 指标集 $\{1, 2, \dots, M\}$
- 编码函数(encoding function)

$$x^n : \{1, 2, \dots, M\} \rightarrow \mathcal{X}^n$$

生成码字(codewords) $x^n(1), x^n(2), \dots, x^n(M)$ , 所有码字的集合称为码本(code-book)

$$\mathcal{C} = \{x^n(1), x^n(2), \dots, x^n(M)\} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_M\}$$

- 译码函数

$$g : \mathcal{Y}^n \rightarrow \{1, 2, \dots, M\}$$

**Definition 5.1.7** (条件误差概率). 已知指标 $i$ 被发送, (给定发送符号时的) 条件误差概率(conditional probability of error)为

$$\lambda_i = P\{g(Y^n) \neq i | X^n = x^n(i)\}$$

它衡量了特定符号在传输过程中的脆弱性或抗干扰能力。

已知接收到符号 $y$ , (给定接收符号时的) 条件误差概率为

$$1 - \max_x P\{X = x | Y = y\}$$

反映了收到特定 $y$ 后, 接收端对这次判决的不确定性。条件误差概率通常指前者。

**Definition 5.1.8.**  $(M, n)$ 码的最大误差概率(maximum probability of error)为

$$\lambda^{(n)} = \max_{i \in \{1, 2, \dots, M\}} \lambda_i$$

(算数) 平均误差概率(average probability of error)为

$$P_e^{(n)} = \bar{\lambda} = \frac{1}{M} \sum_{i=1}^M \lambda_i$$

*Remark 5.1.1.* 如果指标 $W$ 的选取服从均匀分布, 则 $P_e^{(n)} = P\{W \neq g(Y^n)\}$ 。

*Remark 5.1.2.* 显然,  $P_e^{(n)} \leq \lambda^{(n)}$ 。理应希望这二者差异大, 但将证明: 在相同码率下, 平均误差概率小  $\implies$  最大误差概率小



**Definition 5.1.9** (码率).  $(M, n)$ 码的码率(rate)为

$$R = \frac{\log M}{n} (\text{bit/传输})$$

如果存在一个  $(\lceil 2^{nR} \rceil, n)$  码, 满足  $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ , 则称码率  $R$  是可达的(achievable)。一般将此编码简记为  $(2^{nR}, n)$ 。

信道容量定义为可达码率的上确界。

## 5.2 联合典型序列

**Definition 5.2.1** (联合典型序列). 服从分布  $p(x, y)$  的联合典型序列(jointly typical sequence)  $\{(x^n, y^n)\}$  所构成的集合  $A_\epsilon^{(n)}$  是指其经验熵与真实熵以  $\epsilon$  为界靠近的  $n$  长序列构成的集合, 即:

$$A_\epsilon^{(n)} = \{(x^n, y^n) \in \mathcal{X}^n \times \mathcal{Y}^n : \begin{aligned} &\left| -\frac{1}{n} \log p(x^n) - H(X) \right| < \epsilon, \\ &\left| -\frac{1}{n} \log p(y^n) - H(Y) \right| < \epsilon, \\ &\left| -\frac{1}{n} \log p(x^n, y^n) - H(X, Y) \right| < \epsilon \end{aligned}\}$$

其中

$$p(x^n, y^n) = \prod_{i=1}^n p(x_i, y_i)$$

定义包括单独典型+联合典型, 即单独出现概率高, 且联合出现被认为是合理的。

**Theorem 5.2.1** (联合AEP). 设  $(X^n, Y^n)$  为服从  $p(x^n, y^n) = \prod_{i=1}^n p(x_i, y_i)$  的 *i.i.d.* 的  $n$  长序列, 则

$$\textcircled{1} P\{(X^n, Y^n) \in A_\epsilon^{(n)}\} \rightarrow 1, n \rightarrow \infty$$

$$\textcircled{2} |A_\epsilon^{(n)}| \leq 2^{n(H(X, Y) + \epsilon)}$$

③如果  $(\tilde{X}^n, \tilde{Y}^n) \sim p(x^n)p(y^n)$  (i.e.  $\tilde{X}^n$  与  $\tilde{Y}^n$  独立且具有  $p(x^n, y^n)$  的边界分布, 与  $X^n, Y^n$  分别同分布), 则

$$P\{(\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)}\} \leq 2^{-n(I(X; Y) - 3\epsilon)}$$

且对于充分大的  $n$ , 有

$$P\{(\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)}\} \geq (1 - \epsilon)2^{-n(I(X; Y) + 3\epsilon)}$$

**Proof.** ①由弱大数定律,

$$-\frac{1}{n} \log p(X^n) \rightarrow -\mathbb{E} \log p(X) = H(X) \quad \text{依概率}$$

故  $\forall \epsilon > 0, \exists n_1, n > n_1$  时, 有

$$P\left\{\left| -\frac{1}{n} \log p(X^n) - H(X) \right| \geq \epsilon\right\} < \frac{\epsilon}{3}$$

同理,

$$-\frac{1}{n} \log p(Y^n) \rightarrow -\mathbb{E} \log p(Y) = H(Y) \quad \text{依概率}$$

$$-\frac{1}{n} \log p(X^n, Y^n) \rightarrow -\mathbb{E} \log p(X, Y) = H(X, Y) \quad \text{依概率}$$

从而有  $n_2, n_3$ ,

$$n > n_2 \implies P \left\{ \left| -\frac{1}{n} \log p(Y^n) - H(Y) \right| \geq \epsilon \right\} < \frac{\epsilon}{3}$$

$$n > n_3 \implies P \left\{ \left| -\frac{1}{n} \log p(X^n, Y^n) - H(X, Y) \right| \geq \epsilon \right\} < \frac{\epsilon}{3}$$

取  $n > \max\{n_1, n_2, n_3\}$ , 则

$$P\{(X^n, Y^n) \in A_\epsilon^{(n)}\} > 1 - \epsilon$$

②注意到

$$\begin{aligned} 1 &= \sum p(x^n, y^n) \\ &\geq \sum_{A_\epsilon^{(n)}} p(x^n, y^n) \\ &\geq |A_\epsilon^{(n)}| \cdot 2^{-n(H(X, Y) + \epsilon)} \end{aligned}$$

这与要证的式子是等价的。最后一行成立是因为, 根据  $A_\epsilon^{(n)}$  的定义 (最后一条), 每个  $A_\epsilon^{(n)}$  的元素  $(x^n, y^n)$  都满足

$$-n(H(X, Y) + \epsilon) < \log p(x^n, y^n) < -n(H(X, Y) - \epsilon)$$

③在这种假设下, 有

$$\begin{aligned} P \left\{ (\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)} \right\} &= \sum_{(x^n, y^n) \in A_\epsilon^{(n)}} p(x^n) p(y^n) \\ &\leq 2^{n(H(X, Y) + \epsilon)} \cdot 2^{-n(H(X) - \epsilon)} \cdot 2^{-n(H(Y) - \epsilon)} \\ &= 2^{-n(I(X; Y) - 3\epsilon)} \end{aligned}$$

在  $n$  充分大时,  $P \left\{ (\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)} \right\} \geq 1 - \epsilon$ , 因此

$$\begin{aligned} 1 - \epsilon &\leq \sum_{(x^n, y^n) \in A_\epsilon^{(n)}} p(x^n, y^n) \\ &\leq |A_\epsilon^{(n)}| \cdot 2^{-n(H(X, Y) - \epsilon)} \end{aligned}$$

即证后一不等式。 □

### 5.3 信道编码定理

**Theorem 5.3.1** (信道编码定理/香农第二定理). 对于离散无记忆信道, 小于信道容量 $C$ 的所有码率都是可达的, 即 $\forall R < C$ , 存在 $(2^{nR}, n)$ 码使得最大误差概率 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ ; 反之, 任何满足 $\lambda^{(n)} \rightarrow 0, n \rightarrow \infty$ 的 $(2^{nR}, n)$ 码必然满足 $R \leq C$ 。

## 第六章 最后一页