

数理统计

Leo Yan

2026 年 4 月 24 日

目录

第一章 基本概念与统计模型	3
1.1 基本概念	3
1.2 统计推断	3
1.3 统计量	4
1.3.1 常见统计量	4
1.3.2 经验分布函数	6
1.4 统计模型	7
1.5 指数型分布族	7
1.6 贝叶斯模型	8
1.6.1 无信息先验	9
1.6.2 共轭先验	9
第二章 抽样分布和数据的简化	10
第三章 点估计	11
第四章 区间估计	12
第五章 参数假设检验	13

第一章 基本概念与统计模型

1.1 基本概念

Definition 1.1.1. 总体由与研究问题有关的所有个体组成。样本中的个体数目称为**样本大小**，抽取样本的行为称为**抽样**。

根据总体个数有限与无限，分为有限总体和无限总体。

总体也可看作所有个体上某种数量指标的集合，可以用一个随机变量及其概率分布（总体分布）描述。当数量指标有多个时，用随机向量表示总体。

Definition 1.1.2. 样本 $\mathbf{X} = (X_1, \dots, X_n)$ 可能取值的全体，构成**样本空间**，记为 $\mathcal{X}$ 。

样本的两重性：既可看做随机变量（随机向量）（抽样前，Uppercase），又可看作确定的数（抽样后，lowercase）。

简单随机抽样：(1)代表性：等概率抽选；(2)独立性：样本个体值不影响其他值。

Definition 1.1.3 (简单随机样本). 总体（分布） F 中的容量为 n 的样本 $X_1, \dots, X_n$ i.i.d. F 称为**简单随机样本**（简单样本/随机样本）。

1.2 统计推断

Definition 1.2.1. 将出现在样本分布中的未知常数称为**参数（向量）**，如 $N(a, \sigma^2) \rightarrow (a, \sigma^2)$ 。参数的取值范围称为**参数空间**。

Definition 1.2.2. 样本分布包含未知参数时，参数取不同值的样本分布构成分部族：

$$\mathcal{F} = \{F_{\theta}, \theta \in \Theta\} \text{ 或 } \mathcal{F} = \{f_{\theta}, \theta \in \Theta\}$$

其中 $\Theta \in \mathbb{R}^k$ 为参数空间。

Example 1.2.1. 指数分布 $\exp(\lambda)$ 的样本分布族为

$$\mathcal{F} = \{f_{\lambda}(x) = f(x, \lambda) : \lambda > 0\}$$

Definition 1.2.3. 从总体中抽取一定大小的样本去推断总体的概率分布的方法称为**统计推断**(statistical inference)。当样本分布形式已知，而含有未知实参数时的统计推断问题称为**参数统计推断问题**，否则称为**非参数统计推断问题**。

参数统计推断有多种，例如参数估计和假设检验。

1.3 统计量

Definition 1.3.1. 由样本算出的量（样本的函数）称为**统计量**(statistic)。

Remark 1.3.1. • 统计量只允许与样本有关而不允许与未知参数有关

• 统计量也具有两重性

1.3.1 常见统计量

Definition 1.3.2. 设 $X_1, \dots, X_n$ 是从某总体 X 中抽取的样本，称

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

为**样本均值**(sample mean). 称

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

为**样本方差**(sample variance). 称

$$a_{n,k} = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots$$

为**样本k阶原点矩**， $a_{n,1} = \bar{X}$ 。称

$$m_{n,k} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

为**样本k阶中心距**。

Proposition 1.3.1. (1) $\sum_{i=1}^n (X_i - \bar{X}) = 0$

(2) 设 a, b 为常数， $Y_i = aX_i + b$ ，则

$$\bar{Y} = a\bar{X} + b, S_Y^2 = a^2 S_X^2$$

(3) $\forall$ 常数 c ，有

$$\sum_{i=1}^n (X_i - c)^2 \geq \sum_{i=1}^n (X_i - \bar{X})^2$$

即均值是偏差平方最小准则下的最佳估计

Definition 1.3.3 (二维随机向量的样本矩). 设 $(X_1, Y_1), \dots, (X_n, Y_n)$ 为二维样本 $F(x, y)$ 中抽取的样本, 则已定义 $\bar{X}, \bar{Y}, S_X^2, S_Y^2$.

$$S_{XY} = \frac{1}{n}(X_i - \bar{X})(Y_i - \bar{Y})$$

称为X和Y的样本协方差(sample covariance).

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{[(n-1)S_X^2] \cdot [(n-1)S_Y^2]}}$$

称为样本相关系数(sample covariance coefficient).

Definition 1.3.4. 设 $X_1, \dots, X_n$ 是从某总体F中抽取的样本, 按大小排序为 $X_{(1)}, \dots, X_{(n)}$, 称 $(X_{(1)}, \dots, X_{(n)})$ 是样本 $(X_1, \dots, X_n)$ 的次序统计量(order statistics). $(X_{(1)}, \dots, X_{(n)})$ 的一部分也可称为次序统计量。

Definition 1.3.5. • 样本中位数(sample median):

$$m_{\frac{1}{2}} = \begin{cases} X_{((n+1)/2)}, n \text{ 为奇数} \\ \frac{1}{2}[X_{(n/2)} + X_{(n/2+1)}], n \text{ 为偶数} \end{cases}$$

• 样本p分位数($0 < p < 1$)(sample p-fractile):

$$X_{(m)}, m = [(n+1)p]$$

• 样本极值(extremum of sample): $X_{(1)}, X_{(n)}$

• 样本极差(sample range): $R = X_{(n)} - X_{(1)}$ 反映分散程度

Definition 1.3.6. 样本变异系数(sample coefficient of variation)与总体变异系数(population coefficient of variation):

$$\hat{\nu} = \frac{S_n}{\bar{X}t}, \nu = \frac{\sqrt{\text{Var}(X)}}{\mathbb{E}(X)}$$

后者以总体均值为单位度量总体分布的分散程度, 前者反映后者的信息。

Definition 1.3.7. 样本偏度(sample skewness):

$$\hat{\beta}_1 = \frac{m_{n,3}}{m_{n,2}^{3/2}} = \frac{\sqrt{n} \sum_{i=1}^n (X_i - \bar{X})^3}{(\sum_{i=1}^n (X_i - \bar{X})^2)^{3/2}}$$

总体偏度(population skewness):

$$\beta_1 = \frac{\mu_3}{\mu_2^{3/2}}$$

其中 μ_k 为总体的k阶中心矩。

后者衡量总体分布的非对称性, 前者反映后者的信息。

Definition 1.3.8. 样本峰度(sample kurtosis):

$$\hat{\beta}_2 = \frac{m_{n,4}}{m_{n,2}^2} - 3 = \frac{n \sum_{i=1}^n (X_i - \bar{X})^4}{\left(\sum_{i=1}^n (X_i - \bar{X})^2\right)^2} - 3$$

总体峰度(population kurtosis):

$$\beta_2 = \frac{\mu_4}{\mu_2^2} - 3$$

其中 μ_k 为总体的 k 阶中心矩。

后者衡量概率密度函数在众数（最大值）附近尖锐程度，前者反映后者的信息。

1.3.2 经验分布函数

Definition 1.3.9. 设有 $F(x)$ 的次序统计量 $X_{(1)}, \dots, X_{(n)}$ ，称函数

$$F_n(x) = \begin{cases} 0, & x < X_{(1)} \\ \frac{k}{n}, & X_{(k)} \leq x < X_{(k+1)}, k = 1, 2, \dots, n-1 \\ 1, & X_{(n)} \leq x \end{cases}$$

为经验分布函数(empirical distribution function).

经验分布函数单调不减、右连续，是 $F(x) = \mathbb{P}(X \leq x)$ 的统计量。

定义示性函数

$$I_A(x) = \begin{cases} 1, & x \in A \\ 0, & \text{otherwise} \end{cases}$$

则

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i)$$

在时刻 x 以前， X_i 发生了吗？

$$Y_i(x) = I_{(-\infty, x]}(X_i) \implies P(Y_i(x) = 1) = F(x), Y_1, \dots, Y_n \text{ i.i.d. } \sim B(1, F(x))$$

$$\implies nF_n(x) = \sum_{i=1}^n Y_i \sim B(n, F(x))$$

由此可得 $F_n(x)$ 的大样本性质：

Theorem 1.3.2. (1) 由中心极限定理，

$$\frac{\sqrt{n}(F_n(x) - F(x))}{\sqrt{F(x)(1 - F(x))}} \xrightarrow{\mathcal{L}} N(0, 1), n \rightarrow \infty$$

其中 $\xrightarrow{\mathcal{L}}$ 表示依分布收敛

(2) 由 Bernoulli（或辛钦）大数定律，

$$F_n(x) \xrightarrow{\mathbb{P}} F(x), n \rightarrow \infty$$

(3)由Borel大数定律, 以概率1收敛 (a.e.收敛):

$$\mathbb{P}(\lim_{n \rightarrow \infty} F_n(x) = F(x)) = 1$$

(4)(Glivenko-Cantelli定理)用 D_n 衡量 $F_n(x)$ 总体上靠近 $F(x)$ 的程度:

$$D_n = \sup_{-\infty < x < \infty} |F_n(x) - F(x)|$$

则有

$$\mathbb{P}(\lim_{n \rightarrow \infty} D_n = 0) = 1$$

1.4 统计模型

一个问题的统计模型(statistical model)就是研究该问题时所抽样本的分布, 又称概率模型, 例如正态(分布)模型、泊松(分布)模型。

1.5 指数型分布族

Definition 1.5.1. 设 $\mathcal{F} = \{f(x, \theta) : \theta \in \Theta\}$ 是定义在样本空间 $\mathcal{X}$ 上的分布族, 若概率密度函数可以表示为以下形式:

$$f(x, \theta) = C(\theta) \exp \left[\sum_{i=1}^k Q_i(\theta) T_i(x) \right] h(x)$$

则称此分布族为指数型分布族/指数族(exponential family), 其中 $k \in \mathbb{N}^*$, $C(\theta) > 0$, $h(x) > 0$.

Remark 1.5.1. 指数族中的所有概率密度函数 $f(x, \theta)$ 的对 x 的支集必然不依赖于 θ .

Definition 1.5.2. 如果指数族的概率密度函数有如下形式:

$$f(x, \theta) = C^*(\theta) \exp \left[\sum_{i=1}^k \theta_i T_i(x) \right] h(x)$$

则称它为指数族的自然形式(natural form), 此时集合

$$\Theta^* = \left\{ (\theta_1, \dots, \theta_k) : \int_{\mathcal{X}} \exp \left[\sum_{i=1}^k \theta_i T_i(x) \right] h(x) ds < \infty \right\}$$

称为自然参数空间(natural parametric space).

Remark 1.5.2. 其中的参数组 θ 可能不是原分布中的参数组, 而是令 $\varphi_i = Q_i(\theta)$ 再改写符号 φ 为 θ .

Theorem 1.5.1. 指数族的自然形式下, 自然参数空间为凸集。

Theorem 1.5.2. 设指数族的自然形式下, 自然参数空间有内点, 记 $\Theta_0 = \text{int}\Theta^*$. 设实函数 $g(x)$ 使得以下积分在 Θ_0 内存在且有限:

$$G(\theta) = \int_{\mathcal{X}} g(x) \exp \left[\sum_{j=1}^k \theta_j T_j(x) \right] h(x) dx$$

则 $G(\theta)$ 的任意偏导数存在且可以与积分号换序。

1.6 贝叶斯模型

全概率+条件概率 $\implies$

Theorem 1.6.1 (贝叶斯公式(Bayes formula)). 设 $\{B_1, \dots, B_n\}$ 是样本空间 Ω 的完备事件群(分划), A 为 Ω 中的事件, 且 $\mathbb{P}(B_i) > 0, \mathbb{P}(A) > 0$, 则

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_{j=1}^n \mathbb{P}(A|B_j)\mathbb{P}(B_j)}, i = 1, \dots, n$$

Remark 1.6.1. $\mathbb{P}(B_i)$ 为 A 未发生时对时间 B_i 发生可能性大小的估计, 而 $\mathbb{P}(B_i|A)$ 是在已知 A 发生后(新信息), 对 B_i 的发生可能性大小的新的认识。

“结果”推“原因”: 已知结果 A , 估计是哪一个原因导致 A 发生。

统计推断使用的三种信息:

- 总体信息
- 样本信息
- 先验信息: 抽样之前有关统计推断问题中未知参数的一些信息

基于前两者: 经典统计学; 基于全部三者: Bayes 统计学。

Definition 1.6.1. 参数空间 Θ 上 θ 的任一概率分布称为先验分布(prior distribution), 记为 $\pi(\theta)$.

Definition 1.6.2. 在获得样本 $\mathbf{X} = \mathbf{x}$ 后, θ 的后验分布(posterior distribution)记为 $\pi(\theta|\mathbf{x})$, 满足

$$\pi(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta)}{m(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta)}{\int_{\Theta} f(\mathbf{x}|\theta)\pi(\theta) d\theta}$$

其中 $f(\mathbf{x}|\theta)$ 为样本 $\mathbf{x}$ 的条件概率密度函数, $f(\mathbf{x}, \theta)$ 为 $\mathbf{X}, \theta$ 的联合概率密度函数, $m(\mathbf{x})$ 是 $\mathbf{X}$ 的边缘分布。离散情形下, 这个公式就是 Bayes 公式。

先验分布是抽取样本 $\mathbf{X}$ 之前对参数 θ 的认识, 后验分布是抽取样本之后对 θ 的认识。

Bayes 学派: 对参数 θ 的统计推断必须基于 θ 的后验分布。

先验分布的获取:

- 主观概率

- 无信息先验
- 共轭先验

1.6.1 无信息先验

Θ 有界时，无信息先验即均匀分布； Θ 无界时可以使用广义先验分布：

Definition 1.6.3. 设随机变量 $X \sim f(x|\theta), \theta \in \Theta$ ，若 θ 的先验密度 $\pi(\theta)$ 满足

1. $\pi(\theta) \geq 0$ 且 $\int_{\Theta} \pi(\theta) d\theta = \infty$
2. 后验密度 $\pi(\theta|x)$ 是概率密度函数

则称 $\pi(\theta)$ 为 θ 的广义（无信息）先验密度(improper prior density).

常取 $\pi(\theta) \equiv 1$ （乘以正常数无影响），此时

$$\pi(\theta|\mathbf{x}) = \frac{f(\mathbf{x}|\theta)}{\int_{\Theta} f(\mathbf{x}|\theta) d\theta}$$

位置参数族： 概率密度函数形如 $f(x - \theta)$ ， θ 为位置参数。认为 X 与 $Y = X + c$ 有相同的统计问题结构，于是有相同的无信息先验，此时 $\pi(\theta) \equiv 1$.

刻度参数族： 总体分布族的密度函数形如 $\sigma^{-1}\varphi(x/\sigma)$ ， $\sigma > 0$ 为刻度参数。认为 X 与 $Y = cX$ ($c > 0$) 有相同的统计问题结构，于是有相同的无信息先验，此时 $\pi(\sigma) = 1/\sigma$.

1.6.2 共轭先验

Definition 1.6.4. 设 $\mathcal{F}$ 表示又 θ 的先验分布 $\pi(\theta)$ 构成的分布族，如果 $\forall \pi \in \mathcal{F}$ 及样本 $\mathbf{x}$ ，后验分布 $\pi(\theta|\mathbf{x}) \in \mathcal{F}$ ，则称 $\mathcal{F}$ 是一个共轭先验分布族(conjugate prior distribution family).

共轭先验分布易于计算，并且其后验分布中一些参数可以得到很好的解释。

第二章 抽样分布和数据的简化

第三章 点估计

第四章 区间估计

第五章 参数假设检验